POSTECH · FIAP

Tech Challenge · Fase 1

Cardio IA

Apoio à triagem de doença cardiovascular com aprendizado de máquina

Relatório técnico

Integrantes

Guilherme Saar Santos	github.com/GuilhermeSaarSantos
Wesley Berto	github.com/WesleyBert
Michel Zarif	github.com/MichelZarif
Luis Felipe Laudacio	github.com/luislaudacio
Sara Felix	github.com/sarafelix25

Repositório: https://github.com/team-tech-challenge-fiap/tech-challenge-2026-fiap

Vídeo de demonstração: em andamento

28 de outubro de 2026

Sumário

1. Problema
2. Dataset
3. Exploração de dados
4. Estratégias de pré-processamento
5. Modelos usados e por quê
6. Resultados
7. Interpretação (feature importance / SHAP)
8. Discussão crítica (uso na prática — o médico tem a palavra final)
9. Conclusão
10. Extra: diagnóstico por imagem de ECG (CNN)

1. Problema

As doenças cardiovasculares são a principal causa de morte no mundo, segundo a Organização Mundial da Saúde. Muitos casos só são descobertos quando já há sintomas graves, porque o diagnóstico depende de exames que nem sempre estão ao alcance de todos os pacientes.

Este projeto constrói um modelo de **triagem**: a partir de dados simples, que qualquer consulta de rotina coleta (idade, sexo, altura, peso, pressão arterial, colesterol, glicose e hábitos de vida), ele estima se o paciente tem doença cardiovascular. O objetivo não é diagnosticar, e sim **priorizar** quais pacientes devem fazer exames mais completos primeiro. Por isso o erro mais grave é o falso negativo (um doente classificado como saudável), e o **recall** é a métrica mais importante, acompanhado de precision, F1 e AUC. O médico mantém a decisão final.

2. Dataset

Os dados são do *Cardiovascular Disease Dataset*, do Kaggle (https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset): **70.000 pacientes** e 13 colunas (arquivo `data/raw/cardio_train.csv`, separador `;`). O `id` é só um identificador e `cardio` é o alvo (1 = doença cardiovascular), o que deixa **11 variáveis** para o modelo, de três tipos:

Tipo	Variáveis	Observação
Objetivas	idade, sexo, altura, peso	medidas ou registradas pela clínica; a idade vem em dias e é convertida para anos
De exame	pressão sistólica e diastólica, colesterol, glicose	pressão em mmHg; colesterol e glicose em 3 níveis (normal, acima, muito acima)
Subjetivas	fumo, álcool, atividade física	**autodeclaradas** (sim/não), logo menos confiáveis

O alvo é **balanceado**: 35.021 pacientes sem doença e 34.979 com doença (≈ 50% / 50%). Por isso a acurácia também é informativa e não foi preciso reamostrar. Os pacientes têm de 29,6 a 64,9 anos, e 65% são mulheres. Não há valores ausentes. O principal problema do dataset é a **qualidade dos registros** (seção 3).

3. Exploração de dados

Os detalhes ficam nos notebooks `01_eda_visao_geral.ipynb` (T03), `02_eda_demografia_imc.ipynb` (T04), `03_eda_pressao_arterial.ipynb` (T05), `04_eda_exames_habitos.ipynb` (T06) e `08_eda_correlacao.ipynb` (T07); as figuras estão em `results/figures/`.

3.1 Problemas de qualidade

- **Duplicados:** 24 linhas idênticas se ignorarmos o `id` (48 registros). Mantê-las colocaria o mesmo paciente no treino e na validação, inflando o resultado.
- **Pressão arterial impossível:** a sistólica vai de −150 a 16.020 mmHg e a diastólica de −70 a 11.000, e há pacientes com diastólica maior ou igual à sistólica.
- **Altura e peso fora da realidade:** altura de 55 a 250 cm e peso a partir de 10 kg, além de combinações que dão um IMC impossível.
- **Tratamento (T08):** `clean()` remove os registros com erro, em vez de corrigi-los, usando as faixas plausíveis do `config.py`. O dataset passa de **70.000 para 68.509 linhas** (1.491 removidas, 2,1%), e a taxa de doença quase não muda (≈ 50%), então a limpeza não enviesa o alvo. Figuras: `t03_alvo.png`, `t03_faixas.png` e `t03_limpeza.png`.

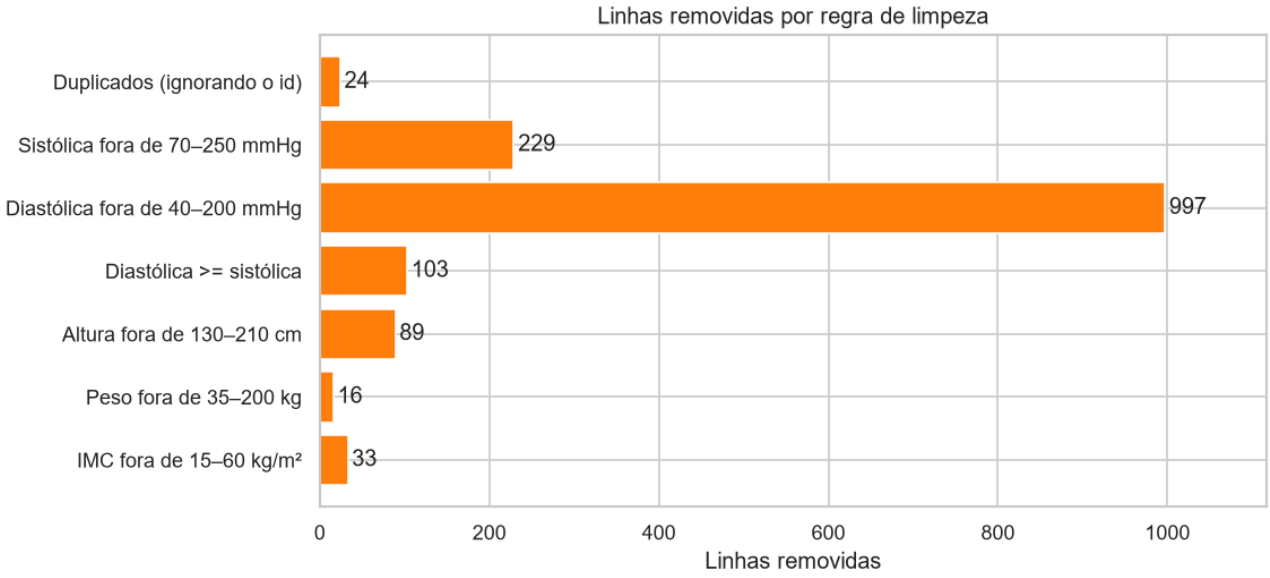


Figura 1. Registros removidos por cada regra de limpeza

3.2 O que se relaciona com a doença

Os números abaixo são sobre os 68.509 pacientes limpos; a taxa de doença é a proporção com `cardio = 1`. As correlações são de Pearson, como na T07. Figuras: `t07_ranking_alvo.png` (correlação de cada variável com a doença), `t07_taxa_por_faixa.png` (taxa de doença por faixa de idade e de pressão, que mostra a forma da relação) e `t06_colesterol_glicose.png` (colesterol e glicose).

Fator	Achado
Pressão arterial (o fator mais forte)	Sistólica e diastólica são as variáveis mais correlacionadas com o alvo (correlação de Pearson de 0,43 e 0,34). Pela classificação ACC/AHA, a taxa de doença é de 22% com pressão normal, 32% na elevada, 39% na hipertensão 1 e **78% na hipertensão 2**.
Idade	A doença cresce de forma contínua com a idade: 24% até 40 anos, 43% entre 45 e 50, 56% entre 55 e 60 e **67% depois dos 60** (correlação de 0,24).
Colesterol	44% de doença com colesterol normal, 60% acima do normal e **76% muito acima** (correlação de 0,22). A glicose segue o mesmo sentido, mais fraca: 48%, 59% e 62% (0,09).
Peso e IMC	A taxa é de 27% abaixo do peso, 40% no peso normal, 51% no sobrepeso e **63% na obesidade** (correlação do IMC de 0,19). A altura isoladamente não tem relação (−0,01).
Sexo	Praticamente nenhuma: 49% das mulheres e 50% dos homens têm doença (correlação de 0,01). Vale a pena lembrar que 65% da amostra são mulheres.
Hábitos	Efeito fraco e, no fumo e no álcool, **contrário ao esperado**: 47% de doença entre fumantes contra 50% entre não fumantes. Quem faz atividade física tem 49% contra 53% de quem não faz.

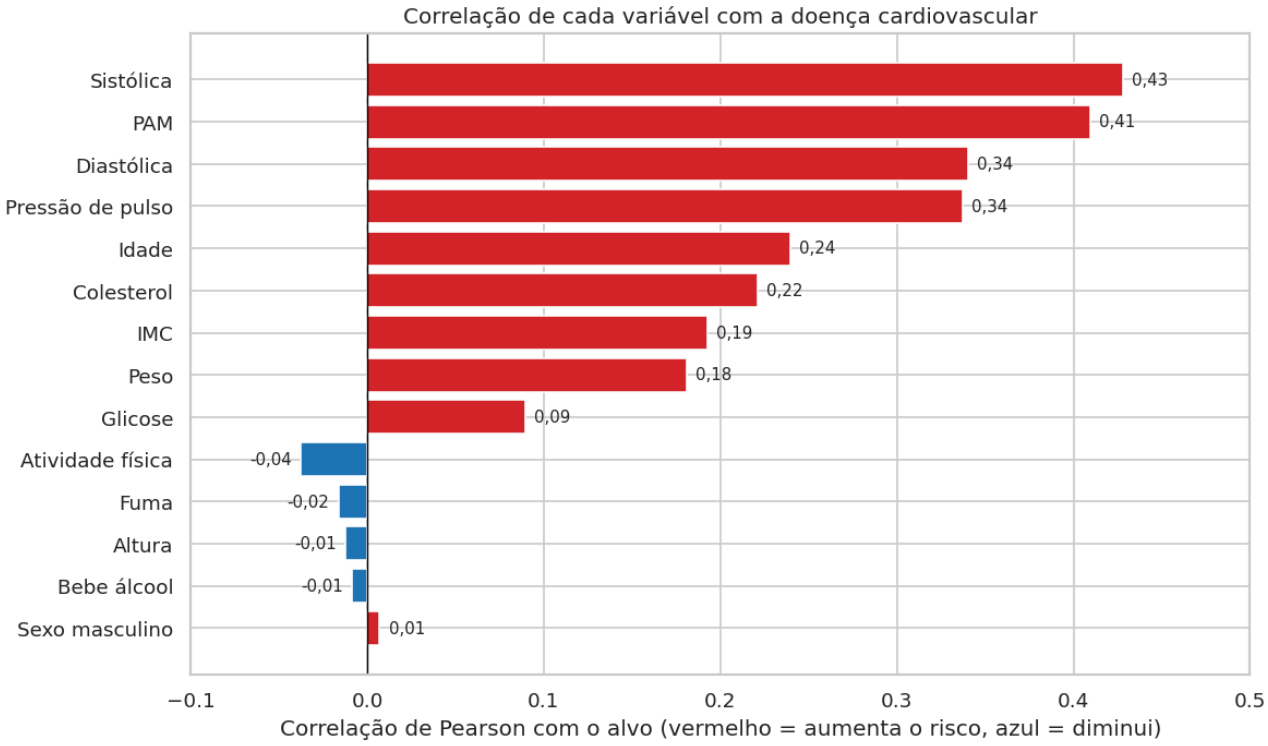


Figura 2. Correlação de cada variável com a doença, nos dados limpos

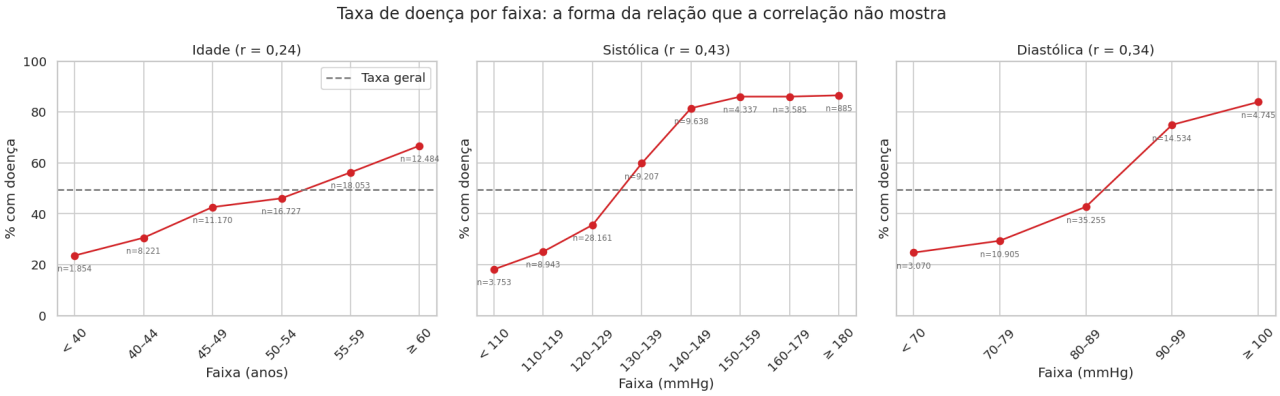


Figura 3. Taxa de doença por faixa de idade e de pressão arterial

A segunda figura mostra o que a correlação não capta: a idade sobe de forma contínua, mas a pressão sistólica tem um degrau entre 120 e 140 mmHg e se estabiliza acima de 140, nos mesmos cortes usados na prática clínica.

3.3 Cuidados com a interpretação

- **Hábitos autodeclarados não são confiáveis.** O resultado "fumar protege o coração" não indica que fumar faça bem: o sinal vem de como a variável foi coletada (subnotificação, quem parou de fumar depois do diagnóstico e uma medida só de sim/não). A T06 testou o efeito de sexo e idade e ele explica só uma parte (figuras `t06_habitos.png` e `t06_fumo_estratificado.png`). Essas variáveis ficam no modelo pelo valor preditivo, mas o efeito delas **não deve ser lido como causal**.
- **Nenhuma variável isolada separa os grupos:** mesmo a pressão, a mais forte, deixa 22% de doentes entre quem tem pressão normal. Isso explica o teto de desempenho dos modelos (acurácia em torno de 73%, AUC em torno de 0,79) e é discutido na análise de erros (T26).
- **Não há vazamento de dados (T07):** o `id` não tem relação com a doença (correlação de 0,004 e AUC de 0,50 usando só o `id`) e fica fora das variáveis do modelo, e nenhuma variável é consequência direta do diagnóstico. A falta de informação sobre o tratamento do paciente é uma limitação do dataset, e não vazamento.

4. Estratégias de pré-processamento

O pré-processamento transforma o arquivo bruto (70.000 pacientes) em dados prontos para os modelos. Ele tem quatro etapas: limpeza dos registros impossíveis, conversão e criação de variáveis, divisão em treino, validação e teste, e preparação das variáveis dentro do pipeline de cada modelo. Todas usam as mesmas funções do código (`clean()`, `load_splits()` e `build_preprocessor()`), então os cinco integrantes treinaram os modelos sobre exatamente os mesmos dados.

4.1 Limpeza: registros impossíveis e duplicados (T08)

O dataset não tem valores ausentes, mas tem **valores fisiologicamente impossíveis**, típicos de erro de digitação: pressão sistólica de −150 ou 16.020 mmHg, diastólica de 11.000 mmHg, adultos com 55 cm de altura ou 10 kg de peso. Esses registros foram **removidos**, e não corrigidos: na maioria dos casos não há como saber qual era o valor certo (um "1100" pode ser 110 ou 100), e corrigir por suposição colocaria no modelo dados inventados. As faixas aceitas foram definidas nas análises exploratórias (T04 e T05):

Regra (aplicada em sequência)	Faixa aceita	Justificativa clínica	Linhas removidas
Duplicados	—	Mesmo paciente registrado duas vezes (todas as colunas iguais, exceto o `id`)	24
Pressão sistólica	70 a 250 mmHg	Abaixo de 70 indica choque circulatório; acima de 250 é extremamente raro e, aqui, eram erros de digitação	229
Pressão diastólica	40 a 200 mmHg	Fora disso são valores digitados com zeros a mais ou negativos	997
Diastólica < sistólica	—	A pressão "de baixo" nunca é maior ou igual à "de cima"	103
Altura	130 a 210 cm	Adultos fora dessa faixa são raríssimos; os casos encontrados eram erros	89
Peso	35 a 200 kg	Abaixo de 35 kg é incompatível com adultos dessas alturas	16
IMC	15 a 60 kg/m²	Pega combinações de altura e peso impossíveis que passam nas regras anteriores	33
Total			**1.491 (2,1%)**

As regras são aplicadas uma após a outra, e cada linha da tabela conta só os registros que aquela regra removeu, por isso a soma bate com o total. Os **24 duplicados** (registros com todas as informações iguais, mudando só o número de identificação) foram removidos primeiro, para que o mesmo paciente não apareça ao mesmo tempo no treino e no teste, o que inflaria artificialmente o resultado.

Depois da limpeza ficam **68.509 pacientes**. A proporção de doentes praticamente não muda (de 49,97% para 49,49%), o que mostra que os registros removidos estavam espalhados entre os dois grupos e a limpeza não desequilibrou as classes. As faixas ficam centralizadas no código (`config.py`), e

testes automatizados confirmam que nenhum valor fora delas sobra depois da limpeza.

4.2 Conversões e variáveis derivadas (T02 e T10)

Duas colunas mudam de formato: a **idade**, que vem em dias no arquivo original, é convertida para anos, e o **sexo** (1 = mulher, 2 = homem) vira uma variável `sex_male` (1 = homem, 0 = mulher), mais fácil de interpretar. O identificador do paciente nunca é usado como variável.

Além das variáveis originais, foram criadas cinco **variáveis derivadas** com significado clínico. Elas são calculadas só a partir das próprias medidas do paciente, nunca a partir do diagnóstico, por isso não "entregam a resposta" ao modelo:

Variável	Como é calculada	Por que pode ajudar
IMC	peso ÷ altura^2	Resume peso e altura num único indicador de excesso de peso, fator de risco conhecido
Pressão de pulso	sistólica − diastólica	Diferença alta indica rigidez das artérias, comum no envelhecimento vascular
Pressão arterial média (PAM)	(sistólica + 2 × diastólica) ÷ 3	Representa a pressão com que o sangue chega aos órgãos
Categoria de pressão	Normal, elevada, hipertensão 1 ou 2 (diretriz ACC/AHA 2017)	Traduz os números na classificação usada na prática médica
Faixa de IMC	Abaixo do peso, normal, sobrepeso ou obesidade (OMS)	Idem, para o peso

Com isso, cada modelo foi treinado com dois **conjuntos de variáveis**: o **A**, com as 11 variáveis originais já limpas (idade, sexo, altura, peso, pressões, colesterol, glicose, fumo, álcool e atividade física), e o **B**, com o A mais as 5 derivadas. Comparar os dois mostra se a engenharia de variáveis traz ganho real. Nos resultados (seção 6), a diferença entre A e B ficou abaixo de 0,01 de AUC em todos os modelos: as derivadas são combinações das variáveis originais, que os modelos já conseguem aproveitar sozinhos.

4.3 Divisão em treino, validação e teste (T09)

Os 68.509 pacientes foram divididos uma única vez, com sorteio fixo (semente 42), em três grupos:

Conjunto	Pacientes	Proporção	Uso
Treino	47.955	70%	Os modelos aprendem com esses pacientes
Validação	10.277	15%	Comparar modelos, escolher hiperparâmetros e o limiar de decisão
Teste	10.277	15%	Avaliação final, **usado uma única vez**

A divisão é **estratificada**: os três grupos têm a mesma proporção de doentes (49,5%), então nenhum fica mais "fácil" que outro. Ela é sempre a mesma, para todos os integrantes e em qualquer computador, e o grupo de cada paciente fica registrado em `results/split_ids.csv`.

O **teste só é usado no final** (T23) porque é o único grupo que simula pacientes nunca vistos. Se fosse usado para escolher o modelo ou ajustar parâmetros, o resultado final ficaria otimista demais, como um aluno que estuda com as questões da própria prova. Por isso, todas as escolhas (hiperparâmetros, conjunto de variáveis e limiar) foram feitas com o treino e a validação. A busca de hiperparâmetros usou, além disso, **validação cruzada de 5 partes dentro do treino**: o treino é dividido em 5 pedaços, e cada combinação é testada 5 vezes, cada vez deixando um pedaço de fora, o que dá uma estimativa mais estável.

4.4 Preparação das variáveis dentro do pipeline (T11)

Antes de chegar ao algoritmo, cada tipo de variável recebe um tratamento:

- **Contínuas** (idade, altura, peso, pressões, IMC, pressão de pulso e PAM): são **padronizadas**, isto é, colocadas na mesma escala (média 0 e desvio-padrão 1). Sem isso, modelos baseados em distância ou em coeficientes, como KNN e Regressão Logística, dariam mais peso ao peso em kg ou à pressão em mmHg só porque os números são maiores. Os modelos de árvore (Random Forest e XGBoost) não precisam disso e recebem os valores originais.
- **Ordinais** (colesterol e glicose, em 3 níveis): mantidas como 1, 2 e 3, porque a ordem tem significado ("muito acima" é mais que "acima").
- **Binárias** (sexo, fumo, álcool e atividade física): mantidas como 0 e 1.
- **Categorias do conjunto B** (categoria de pressão e faixa de IMC): transformadas em uma coluna de sim/não para cada categoria (*one-hot encoding*), porque não são números. Com isso, o conjunto B passa de 16 para 22 colunas.

Esse tratamento fica **dentro do pipeline de cada modelo**, e não é aplicado na base inteira antes da divisão. O motivo é evitar o **vazamento de informação**: a padronização usa a média e o desvio-padrão dos dados, e, se esses valores fossem calculados com todos os pacientes, informações da validação e do teste "vazariam" para o treino. Dentro do pipeline, eles são calculados só com o treino (e, na validação cruzada, só com o pedaço de treino de cada rodada) e depois apenas aplicados aos demais pacientes, exatamente como aconteceria com um paciente novo no hospital.

5. Modelos usados e por quê

Foram avaliados cinco algoritmos de aprendizado de máquina para identificar padrões associados à presença de doenças cardiovasculares. A comparação considerou desempenho preditivo, capacidade de identificar pacientes com a doença, interpretabilidade e custo computacional. Como o objetivo é apoiar a triagem, a sensibilidade (*recall*) recebeu atenção especial: um falso negativo representa um paciente com doença que não foi sinalizado pelo modelo.

Regressão Logística (T15). Foi utilizada como modelo de referência (*baseline*) por sua simplicidade e interpretabilidade. Seus coeficientes permitem compreender a associação de cada variável com a classificação, por meio de medidas como o *odds ratio*. Foram avaliados diferentes valores de regularização (`C`) e o balanceamento das classes. A configuração definida na T15 foi `C=1` e `class_weight="balanced"`, buscando preservar a capacidade de identificar pacientes positivos.

K-Nearest Neighbors — KNN (T16). Classifica um paciente considerando os resultados dos pacientes mais semelhantes presentes no treinamento. Sua inclusão permitiu avaliar uma abordagem baseada em distância, diferente dos modelos lineares e das árvores. Como a distância depende da escala das variáveis, medidas contínuas foram padronizadas. A configuração escolhida utiliza 101 vizinhos com pesos uniformes. Embora o treinamento seja rápido, a previsão exige comparar novos pacientes com os registros armazenados.

Random Forest (T17). Combina 300 árvores de decisão para identificar relações complexas entre fatores como idade, pressão arterial e colesterol. Foi escolhido pela capacidade de representar associações não lineares e reduzir a instabilidade de uma árvore isolada. Os experimentos iniciais apresentaram sobreajuste, posteriormente reduzido por limitações na profundidade das árvores e na quantidade mínima de pacientes por folha.

XGBoost (T18). Utiliza árvores construídas sequencialmente, de modo que cada nova árvore procure corrigir erros das anteriores. Foi incluído por sua eficiência em dados tabulares e pela capacidade de representar interações entre fatores clínicos. Para controlar o sobreajuste, foram utilizadas árvores de profundidade 4 e taxa de aprendizado de 0,03. O conjunto A apresentou AUC ROC de aproximadamente 0,792 na validação e foi selecionado como modelo final do projeto.

Support Vector Machine — SVM (T19). Busca uma fronteira que diferencie pacientes com e sem doença cardiovascular. Para representar relações não lineares sem o elevado custo do kernel RBF exato, foi utilizada a aproximação Nyström, com 500 componentes, seguida de `LinearSVC` calibrado. Essa estratégia apresentou AUC próxima de 0,792 na validação e permitiu aproveitar o conjunto completo de treinamento com menor custo computacional.

Conjuntos de atributos e engenharia de variáveis

Todos os algoritmos foram avaliados com dois conjuntos de atributos. O **conjunto A** contém 11 variáveis clínicas, demográficas e comportamentais, incluindo idade, sexo, medidas corporais, pressão arterial, colesterol, glicose e hábitos de vida. O **conjunto B** acrescenta cinco variáveis derivadas: índice de massa corporal (IMC), pressão de pulso, pressão arterial média (PAM), categoria de pressão e faixa de IMC.

A comparação mostrou diferenças pequenas de AUC ROC entre os conjuntos A e B, inferiores a 0,01. Portanto, a engenharia de variáveis não produziu ganho expressivo na capacidade de discriminação dos modelos. O conjunto A foi preferido para o modelo final por apresentar desempenho competitivo com menor complexidade.

Busca de hiperparâmetros e custo computacional

A otimização utilizou `RandomizedSearchCV`, com validação cruzada estratificada em cinco partes, exclusivamente nos dados de treinamento. O principal critério de escolha foi a AUC ROC, que avalia a capacidade de distinguir as duas classes em diferentes limiares de decisão. O pré-processamento foi executado dentro de cada etapa da validação cruzada, evitando vazamento de informações.

Para o KNN, a busca utilizou uma amostra estratificada de 10.000 pacientes, reduzindo o custo das comparações de distância. Para o SVM, foram testadas abordagens lineares, kernel RBF exato em amostra e aproximação Nyström; esta última foi selecionada pelo equilíbrio entre desempenho e tempo de processamento.

Modelo	Hiperparâmetros principais	Tempo registrado
Regressão Logística	`C=1` ; `class_weight=balanced`	0,21 s*
KNN	`n_neighbors=101` ; `weights=uniform`	0,13 s
Random Forest A	`n_estimators=300` ; `max_depth=10` ; `min_samples_leaf=20` ; `max_features=sqrt`	216,76 s
XGBoost A	`n_estimators=200` ; `max_depth=4` ; `learning_rate=0.03` ; `subsample=0.8` ; `colsample_bytree=0.8`	0,52 s
SVM A	`C=0.1` ; `gamma=0.1` ; Nyström com 500 componentes	29,20 s

Nota: os tempos foram obtidos dos registros disponíveis, mas representam etapas distintas: no Random Forest, o valor inclui a busca de hiperparâmetros; nos demais casos, os registros apresentados correspondem a execuções de treinamento. O tempo da Regressão Logística ainda precisa ser confirmado para a configuração balanceada.

Os resultados comparativos podem ser consultados em `results/comparison_table.csv`, e as curvas ROC dos modelos estão disponíveis em `results/figures/roc_A.png` e `results/figures/roc_A_vs_B_xgb.png`.

Síntese. Os cinco modelos apresentaram capacidade discriminativa semelhante, mas diferiram em interpretabilidade, custo computacional e comportamento de classificação. O XGBoost com o conjunto A foi selecionado para a etapa final, com ajuste posterior do limiar de decisão para priorizar a identificação de pacientes com doença cardiovascular. Os resultados representam validação experimental interna e não autorizam o uso isolado do sistema para diagnóstico médico.

6. Resultados

Esta seção mostra como o modelo foi avaliado e o que ele alcançou. Os números da validação vêm de modelos treinados **apenas com os dados de treino**; o conjunto de teste foi usado **uma única vez**, no final. Todos os valores foram calculados em `notebooks/12_resultados_relatorio.ipynb`.

6.1 Como medimos o desempenho

Como o sistema deve apoiar a triagem, cada métrica responde a uma pergunta clínica diferente:

Métrica	Pergunta que responde	Por que importa aqui
Recall (sensibilidade)	Dos pacientes que têm a doença, quantos o modelo sinaliza?	É a métrica principal: um falso negativo é um doente que sai sem ser visto, o erro mais grave numa triagem.
Precision	Dos pacientes sinalizados, quantos realmente têm a doença?	Mede os alarmes falsos, que geram consultas e exames desnecessários.
F1-score	Qual o equilíbrio entre recall e precision?	Resume as duas em um único número.
AUC ROC	O modelo dá risco maior aos doentes do que aos saudáveis, qualquer que seja o corte?	Compara modelos sem depender do limiar de decisão: 0,5 equivale a sortear e 1,0 é perfeito.
Acurácia	Qual a porcentagem de acertos?	É informativa porque as classes são equilibradas (cerca de 50% cada), mas não distingue os dois tipos de erro.

6.2 Comparação dos modelos na validação

Os cinco modelos foram avaliados nos mesmos 10.277 pacientes de validação, com o limiar padrão de 0,50. A tabela traz o conjunto A (11 variáveis originais) e, na última coluna, a AUC do conjunto B (com variáveis derivadas).

Modelo	Acurácia	Precision	Recall	F1	AUC (conjunto A)	AUC (conjunto B)
XGBoost	72,6%	74,5%	67,9%	71,1%	0,792	0,792
SVM	72,8%	74,1%	69,3%	71,6%	0,792	0,791
Random Forest	72,9%	75,2%	67,3%	71,1%	0,791	0,790
KNN	72,5%	75,3%	66,0%	70,4%	0,785	0,786
Regressão Logística	72,7%	75,0%	67,1%	70,8%	0,783	0,785
Baseline (sorteio)	50,9%	50,4%	49,4%	49,9%	0,508	0,508

Todos os modelos aprendem algo real: o baseline acerta cerca de 51%, e os cinco modelos ficam entre 72,5% e 72,9% de acurácia, com AUC entre 0,783 e 0,792. **A diferença entre os modelos é pequena** (menos de 0,01 de AUC), e o conjunto B não melhora nenhum deles (a maior diferença entre A e B é de 0,002). O XGBoost com o conjunto A foi escolhido por ter a maior AUC (empatada com o SVM e o Random Forest), treinar em menos de um segundo e permitir explicar as decisões com o SHAP (seção 7).

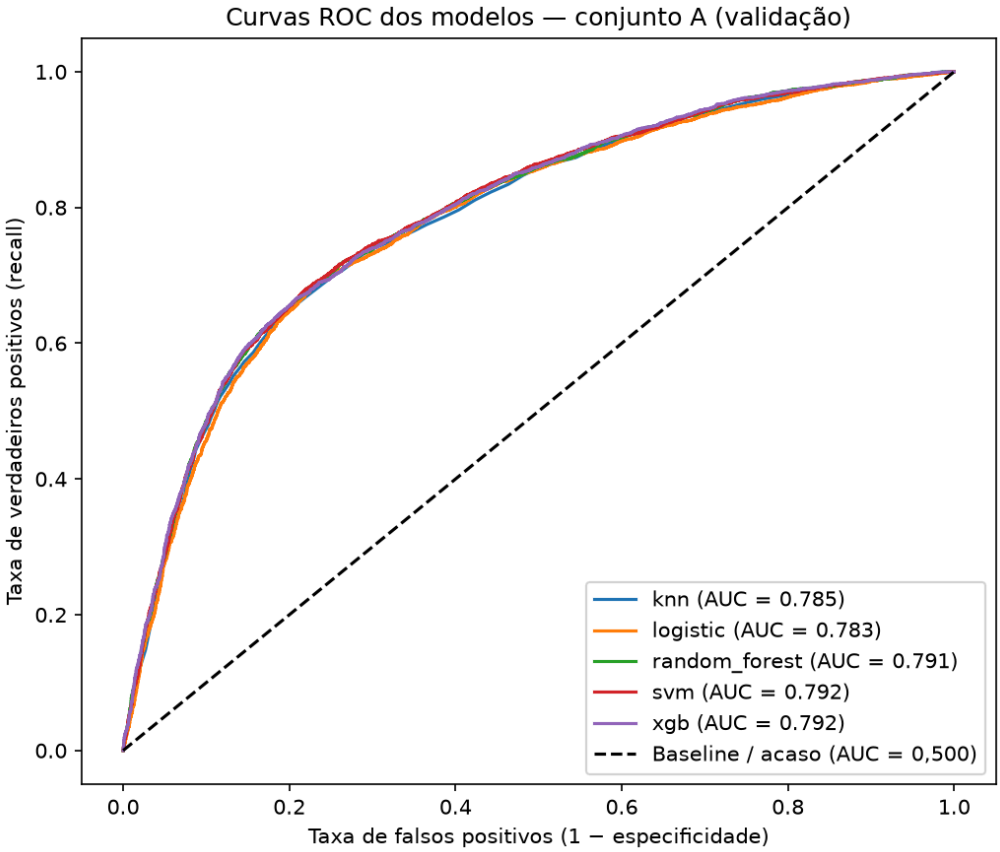


Figura 4. Curvas ROC dos cinco modelos no conjunto A, na validação

As curvas ROC dos cinco modelos praticamente se sobrepõem e ficam bem acima da diagonal do acaso. Nas curvas Precision-Recall, a precisão média vai de 0,761 (Regressão Logística) a 0,775 (XGBoost), contra cerca de 0,495 do baseline, que é a proporção de doentes.

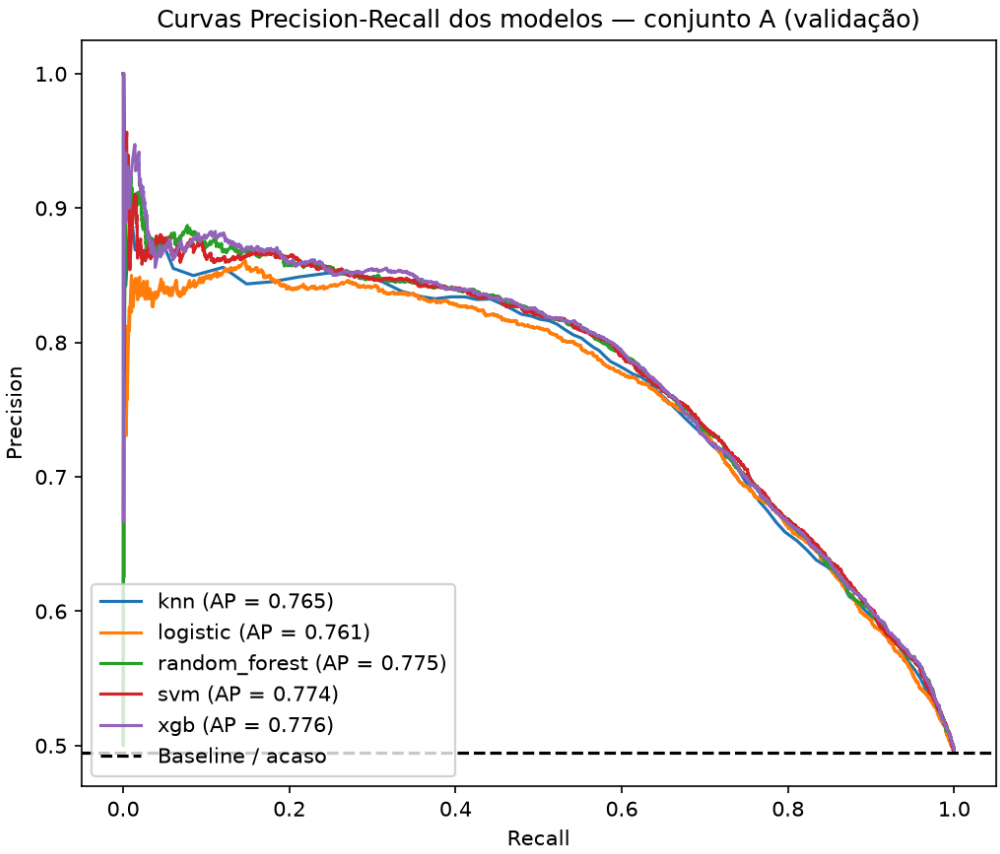


Figura 5. Curvas Precision-Recall dos cinco modelos no conjunto A, na validação

A curva de calibração do XGBoost acompanha a diagonal: em média, a probabilidade prevista difere da frequência real de doença em apenas 1,4 ponto percentual, então a probabilidade pode ser lida como uma estimativa do risco do paciente.

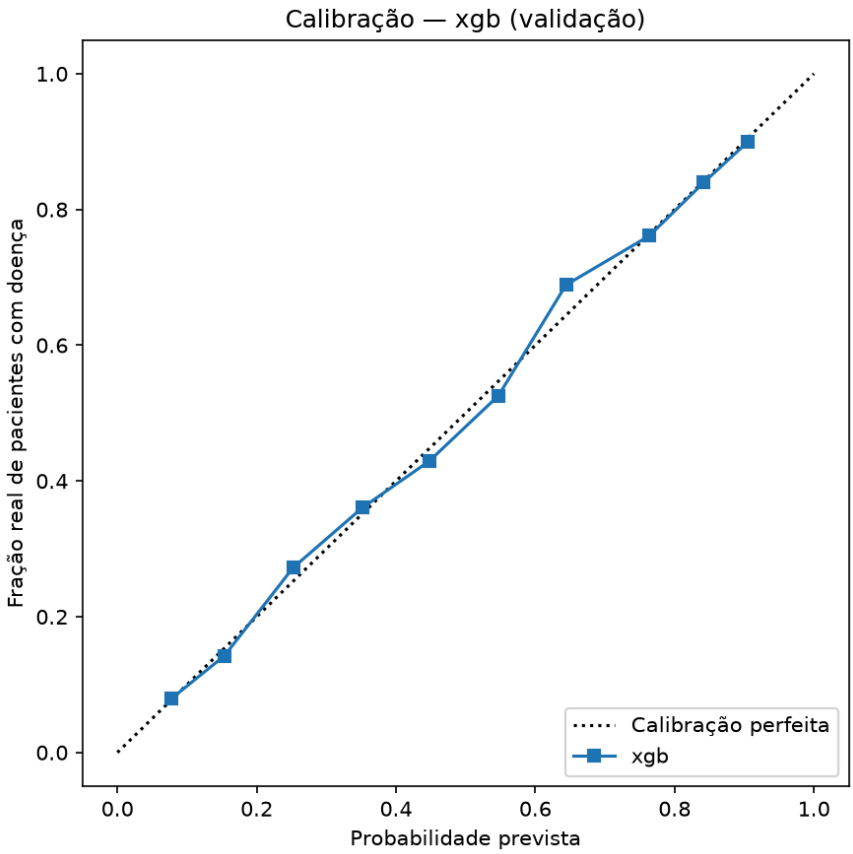


Figura 6. Curva de calibração do XGBoost, na validação

6.3 Limiar de decisão

Com o corte padrão (0,50), o XGBoost deixa de sinalizar cerca de 1 em cada 3 doentes (recall de 67,9%). Como esse é o erro mais grave numa triagem, o limiar foi baixado seguindo uma regra definida **na validação**: o maior limiar que mantém o recall em pelo menos 0,80, o que dá **0,36**.

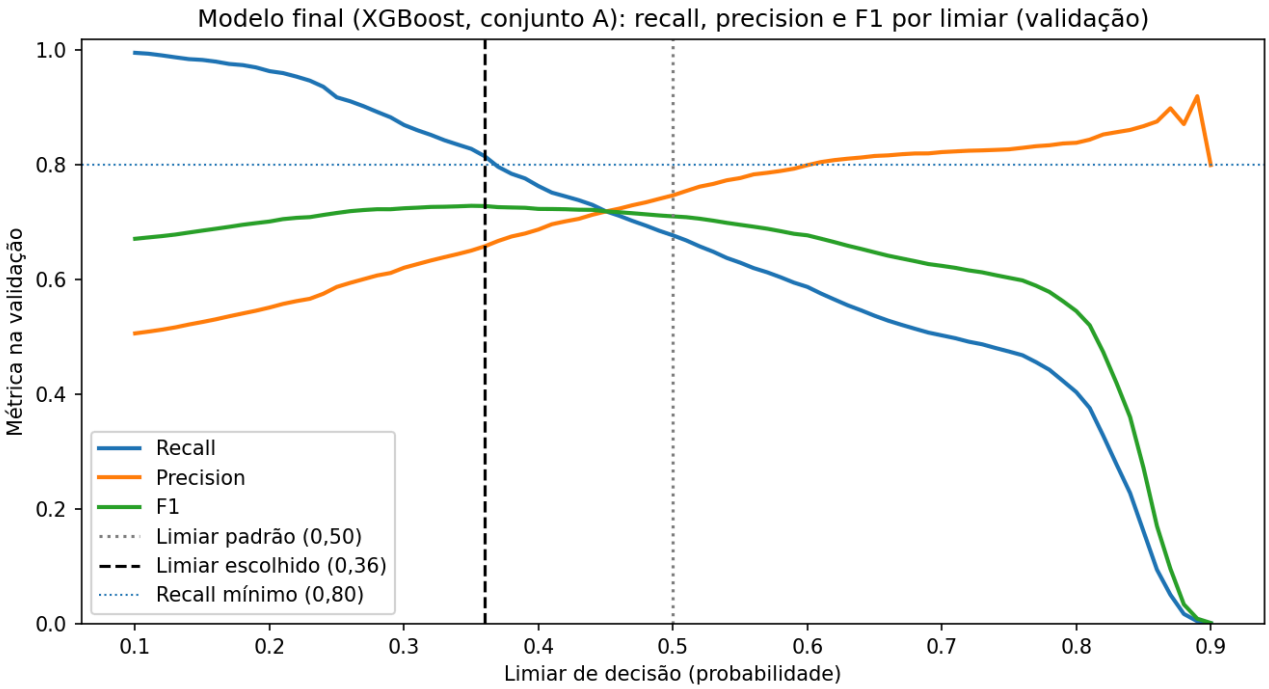


Figura 7. Recall, precision e F1 do modelo final por limiar de decisão, na validação

	Limiar 0,50	**Limiar 0,36**	**Diferença**
Recall	67,9%	81,7%	+13,8 p.p.
Precision	74,5%	65,8%	−8,7 p.p.
Especificidade	77,3%	58,4%	−18,9 p.p.
Doentes **não sinalizados** por 1.000 pacientes	159	91	−68
Saudáveis **encaminhados** por 1.000 pacientes	115	210	+95

A cada 1.000 pacientes avaliados, o limiar de 0,36 faz **68 doentes a mais** serem sinalizados, em troca de **95 encaminhamentos extras** de pessoas saudáveis: cerca de 1,4 alarme falso para cada doente a mais encontrado. A troca é aceitável porque os dois erros têm custos diferentes: um doente não sinalizado pode ficar sem tratamento, enquanto um falso positivo custa uma consulta ou um exame a mais, e o médico confirma o diagnóstico.

6.4 Resultado final no conjunto de teste

O modelo final é o **XGBoost com o conjunto A**, treinado com treino e validação juntos (58.232 pacientes) e com o limiar de 0,36 fixado antes de se olhar o teste. Ele foi avaliado **uma única vez** em 10.277 pacientes que não participaram de nenhuma etapa anterior (5.086 com doença e 5.191 sem).

Métrica	Valor
AUC ROC	0,810
Recall	83,1%
Precision	66,9%
F1-score	74,2%
Especificidade	59,8%
Acurácia	71,3%

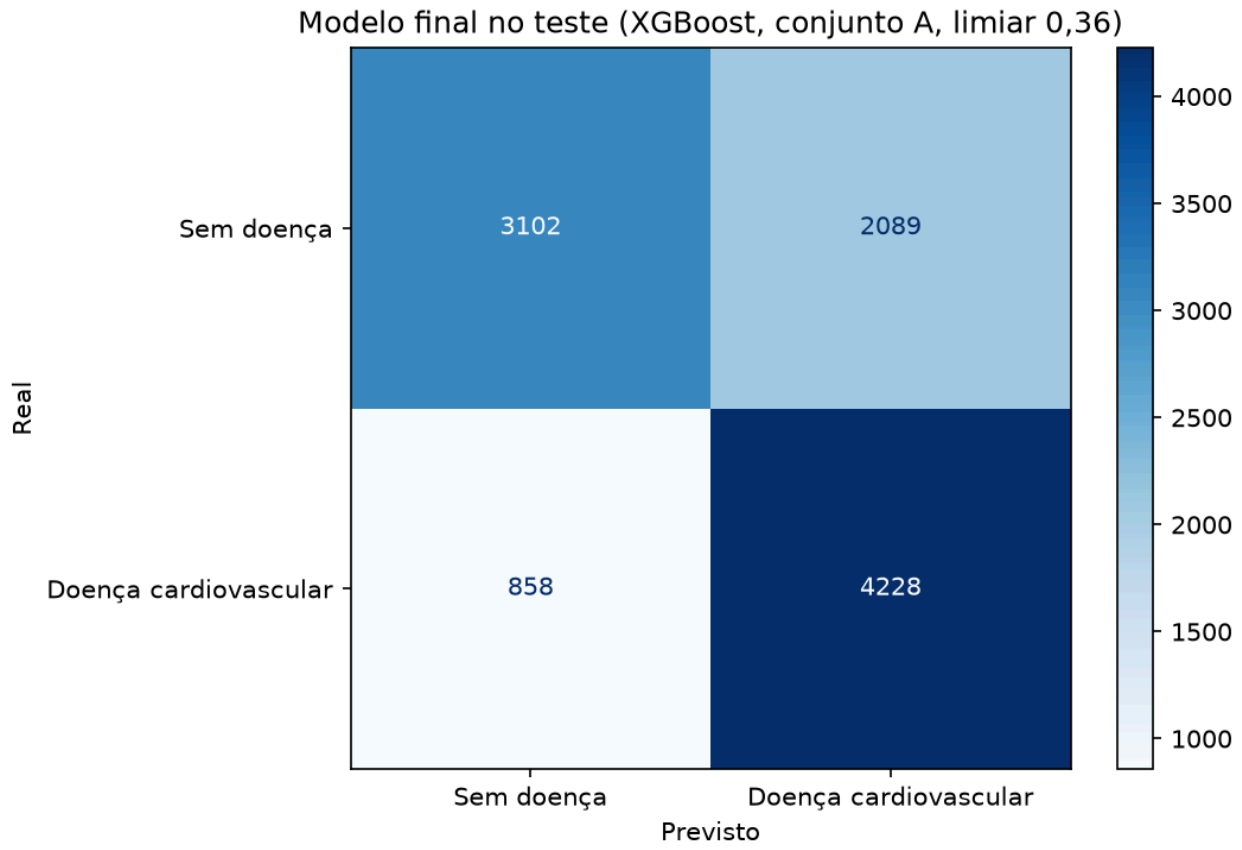


Figura 8. Matriz de confusão do modelo final no conjunto de teste

Dos 5.086 pacientes com doença, o modelo sinalizou **4.228** e deixou de sinalizar **858**. Dos 5.191 saudáveis, liberou 3.102 e encaminhou **2.089** sem necessidade. A cada 1.000 pacientes (49,5% doentes), isso significa 411 doentes sinalizados, **83 não sinalizados**, **203 saudáveis encaminhados** e 302 saudáveis liberados. Entre os pacientes sinalizados, 67 em cada 100 realmente têm a doença. O recall de 83,1% atinge a meta de pelo menos 80% definida para a triagem.

A AUC no teste (0,810) é 0,018 maior que a da validação (0,792). Isso não deve ser lido como uma melhora do modelo: o modelo final usou mais dados de treino e o teste é outra amostra de pacientes. Como há uma única divisão dos dados, não há intervalo de confiança que mostre quão estável é essa diferença.

6.5 Por que o desempenho para perto de 0,79 de AUC?

Quatro verificações com o XGBoost e o conjunto A indicam que o limite está nas informações disponíveis, e não no algoritmo.

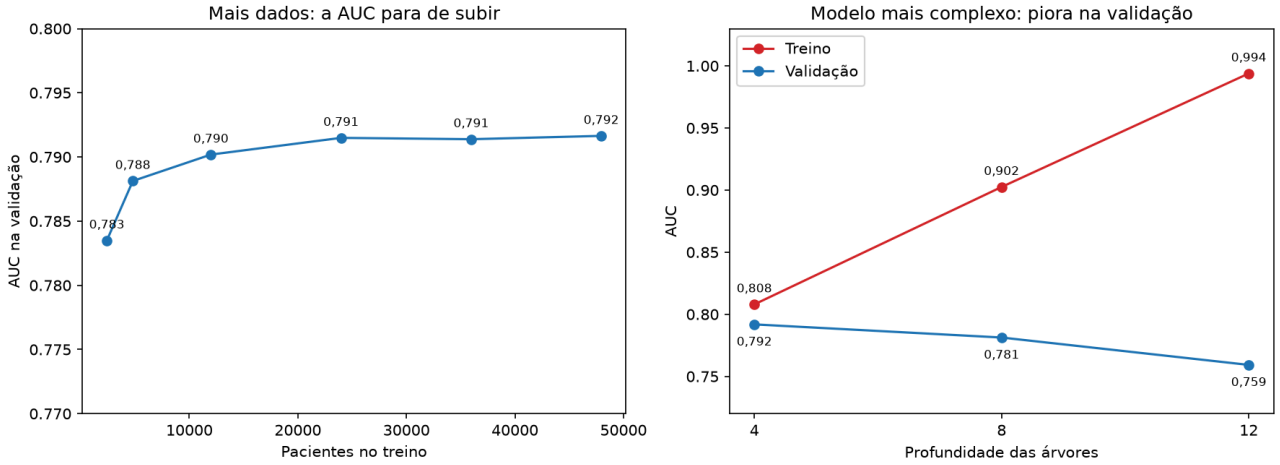


Figura 9. Curva de aprendizado e efeito da complexidade do modelo

- **Mais dados não ajudam.** A AUC na validação é 0,783 com 2.397 pacientes no treino, 0,790 com 11.988, 0,791 com 23.977 e 0,792 com os 47.955: ela para de subir com um quarto a metade do treino.
- **Modelos mais complexos pioram.** Com árvores de profundidade 4, 8 e 12, a AUC no treino sobe (0,808, 0,902 e 0,994), mas na validação cai (0,792, 0,781 e 0,759): o modelo maior decora ruído em vez de aprender padrões.
- **Combinar modelos não ajuda.** A média das probabilidades de Regressão Logística, Random Forest e XGBoost dá AUC de 0,7906, e a dos cinco modelos, 0,7914, ambas abaixo do melhor modelo sozinho (0,7919).
- **A informação é limitada.** Só as duas pressões arteriais já dão AUC de 0,746, contra 0,792 com as 11 variáveis. Além disso, a pressão foi registrada com pouca precisão: 97% das sistólicas e das diastólicas terminam em zero, e 43% dos pacientes têm exatamente 120/80 ou 140/90.

Essa é uma **inferência** a partir dessas verificações, e não uma prova. O que provavelmente melhoraria o resultado são informações que o dataset não tem: valores numéricos de colesterol e glicose (hoje só há três níveis), uso de medicamentos para pressão (que pode deixar a pressão medida "normal" em um paciente doente), histórico familiar, exames como o eletrocardiograma e uma medida de pressão mais precisa.

7. Interpretação (feature importance / SHAP)

Um modelo útil na prática precisa poder ser explicado ao médico. Esta seção mostra quais variáveis o modelo usa, de duas formas: a **importância das variáveis** (T24), que olha o modelo como um todo, e o **SHAP** (T25), que mostra como cada variável empurra o risco de cada paciente.

7.1 Quais variáveis mais pesam

A medida mais confiável aqui é a **importância por permutação**: os valores de uma variável são embaralhados entre os pacientes da validação e mede-se o quanto a AUC cai. Se o modelo piora muito, ele dependia daquela variável. Ela vale igual para qualquer modelo e foi calculada para a Regressão Logística, o Random Forest e o XGBoost.

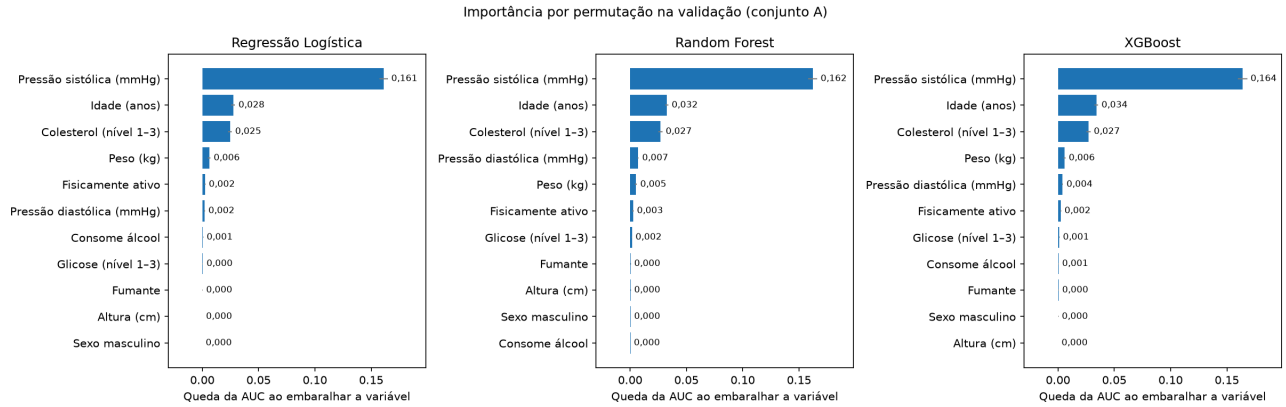


Figura 10. Importância por permutação nos três modelos, na validação

Os **três modelos concordam** nas três variáveis mais importantes e na ordem delas: **pressão sistólica, idade e colesterol**. Embaralhar a pressão sistólica derruba a AUC em 0,161 (Regressão Logística), 0,162 (Random Forest) e 0,164 (XGBoost), de cinco a seis vezes o efeito da idade (0,028, 0,032 e 0,034) e do colesterol (0,025, 0,027 e 0,027). As demais variáveis têm efeito pequeno.

A importância nativa das árvores engana em um ponto: ela coloca a **pressão diastólica** em 2º lugar (20% no Random Forest e 17% no XGBoost), mas pela permutação ela fica em 4º e 5º. É um viés conhecido, porque a diastólica anda junto com a sistólica (correlação de 0,74) e as árvores a usam mesmo quando ela não acrescenta informação.

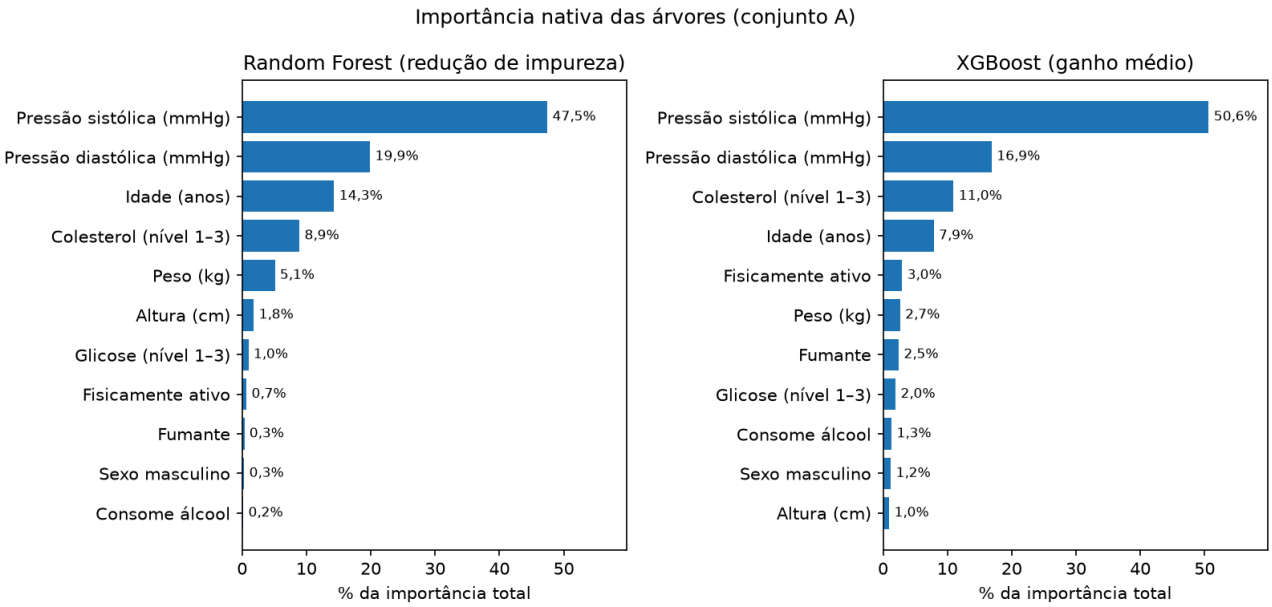


Figura 11. Importância nativa do Random Forest e do XGBoost

A Regressão Logística permite ler o efeito como **odds ratio**, que mostra por quanto a chance de doença é multiplicada, mantendo as outras variáveis iguais:

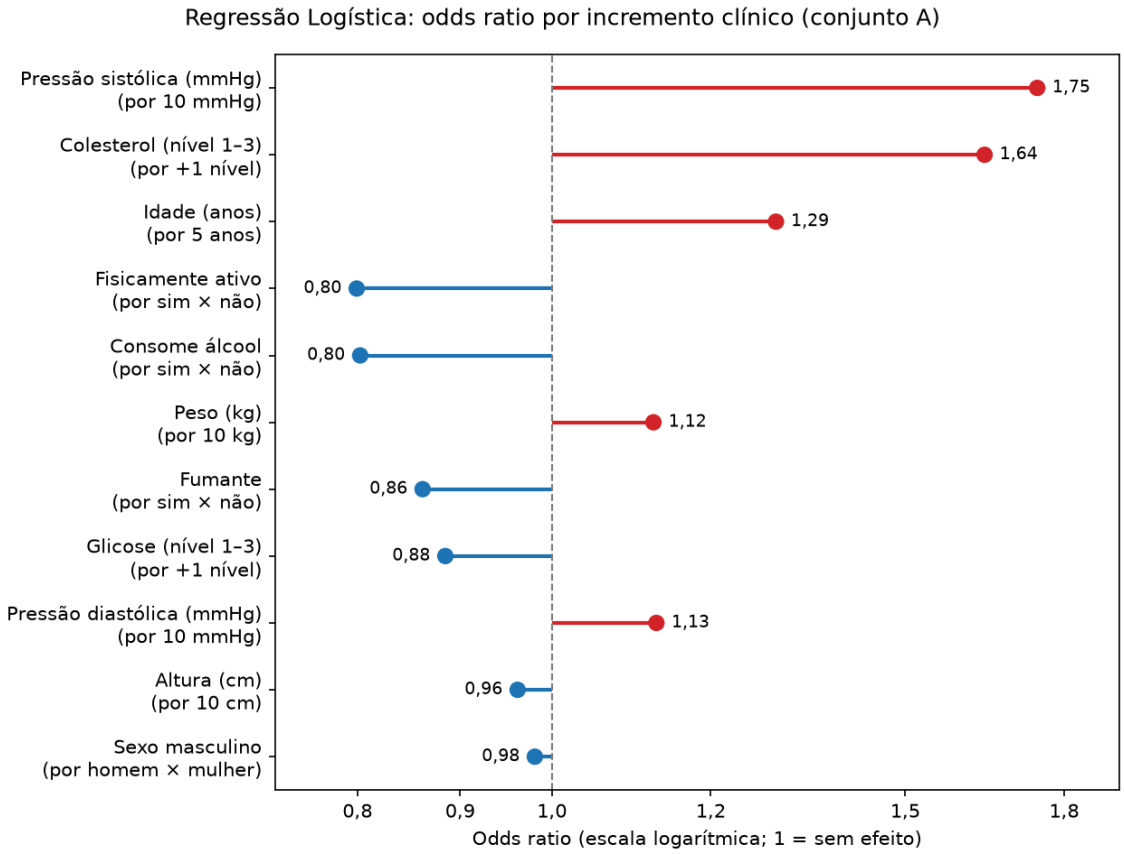


Figura 12. Odds ratio da Regressão Logística por incremento clínico

- **pressão sistólica:** a cada 10 mmHg a mais, a chance é multiplicada por **1,75** (75% maior);
- **idade:** a cada 5 anos, por **1,29**;

- **colesterol:** a cada nível (normal, acima, muito acima), por **1,64**;
- **fumo (0,86), álcool (0,80), glicose (0,88) e atividade física (0,80)** ficam abaixo de 1. Para a atividade física, isso é o esperado. Para fumo e álcool, não se deve ler como efeito protetor: são hábitos autodeclarados e já tinham sinal contrário ao esperado na análise exploratória. A glicose anda junto com o colesterol (correlação de 0,40), e com o colesterol no modelo ela pouco acrescenta.

7.2 Como cada fator decide (SHAP)

O SHAP mede, para cada paciente, quanto cada variável empurra o risco para cima ou para baixo em relação ao risco médio. Foi calculado no modelo final, em 1.500 pacientes da validação.

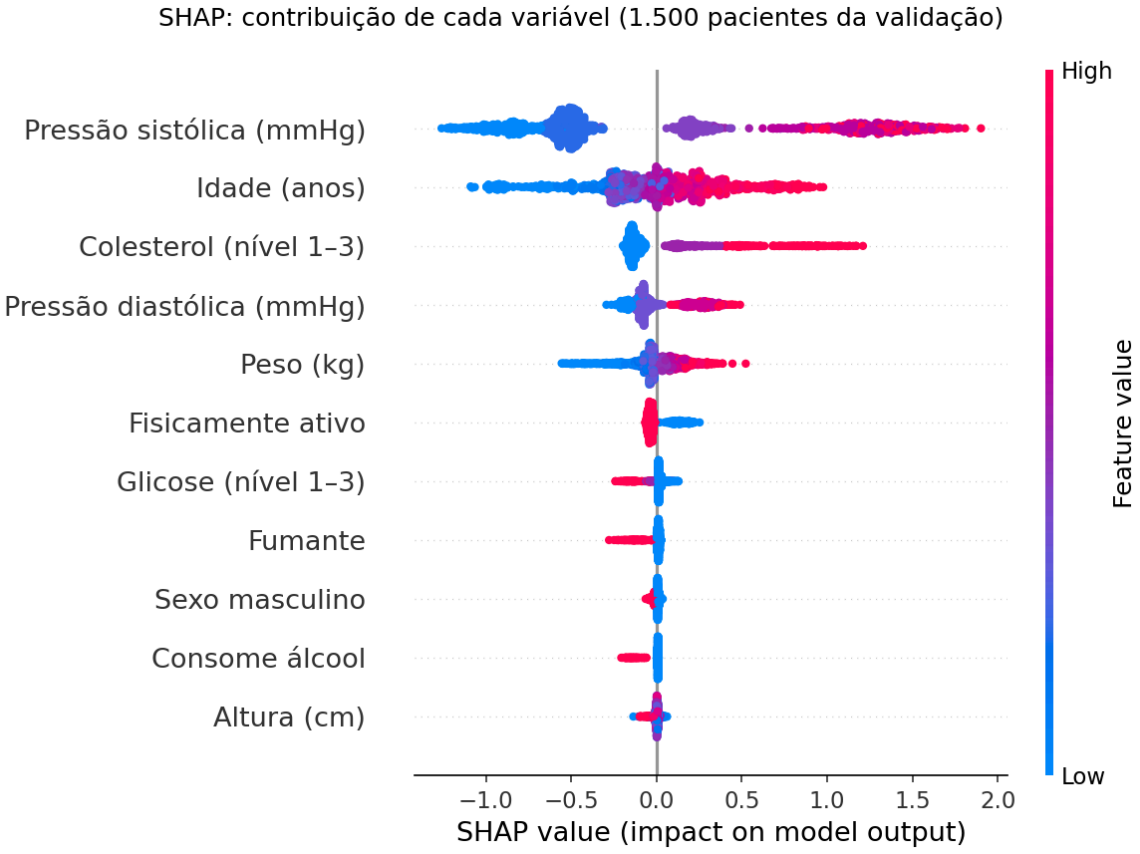


Figura 13. SHAP: contribuição de cada variável para o risco

- Pressão sistólica (46%), idade (17%) e colesterol (13%) respondem por cerca de **76%** de toda a contribuição do modelo.
- A pressão sistólica passa a **aumentar** o risco a partir de **130 mmHg**, o mesmo corte de hipertensão estágio 1 da diretriz ACC/AHA; o modelo aprendeu esse limite sozinho, a partir dos dados.
- A idade age de forma gradual e passa a pesar a favor da doença a partir de **55 anos**.
- Hábitos autodeclarados (fumo, álcool e atividade física), altura e sexo têm peso pequeno.

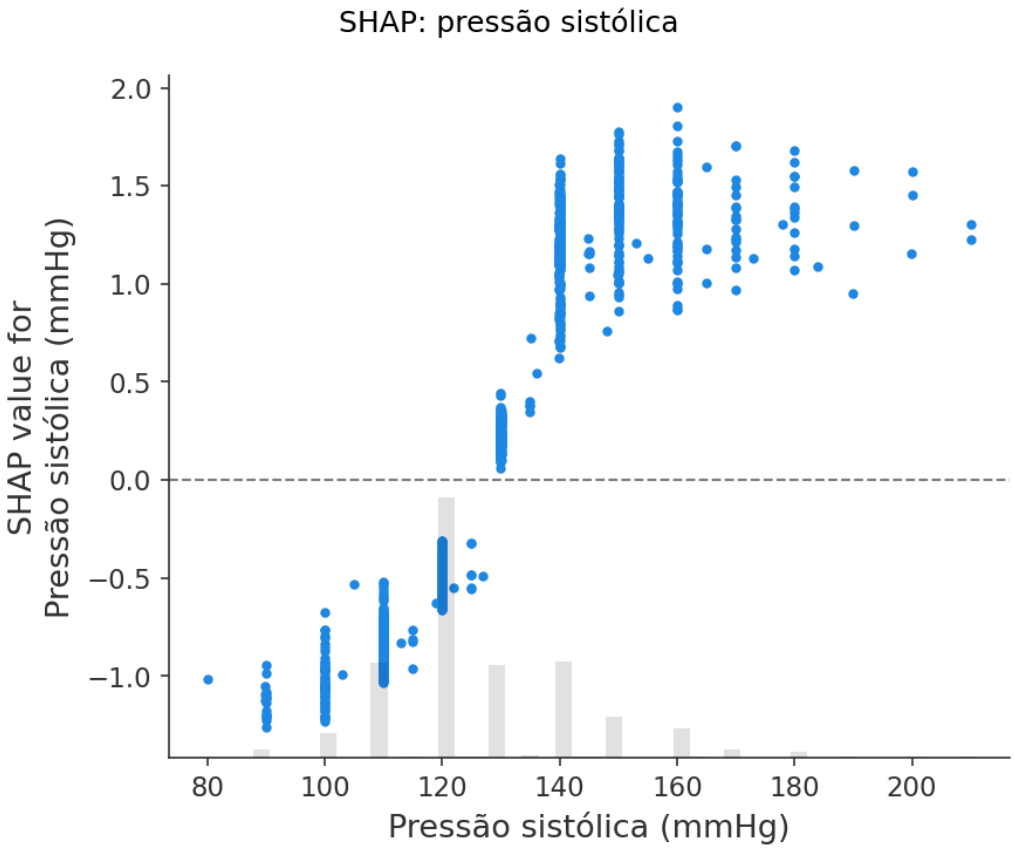


Figura 14. SHAP: contribuição da pressão sistólica conforme o valor

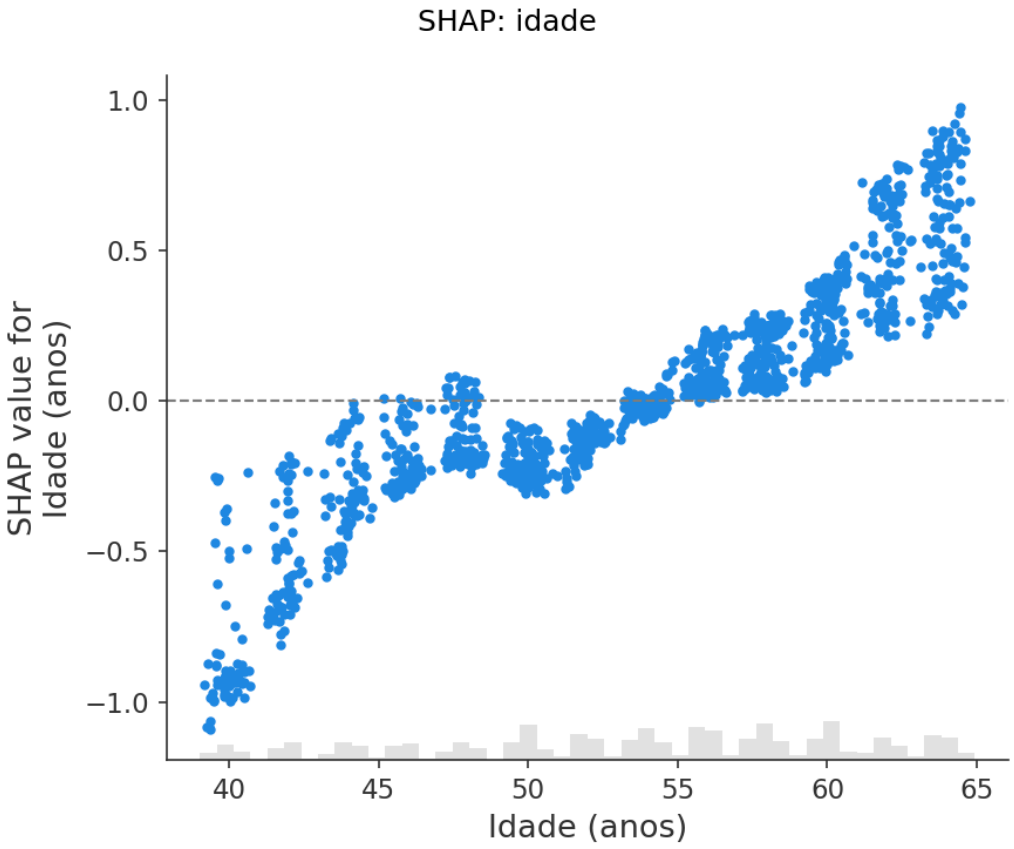


Figura 15. SHAP: contribuição da idade conforme o valor

Cada previsão pode ser explicada ao médico, inclusive os erros: os gráficos de cascata abaixo mostram, para um acerto com doença, um acerto sem doença e um doente não sinalizado, quais variáveis levaram o risco até a previsão final.

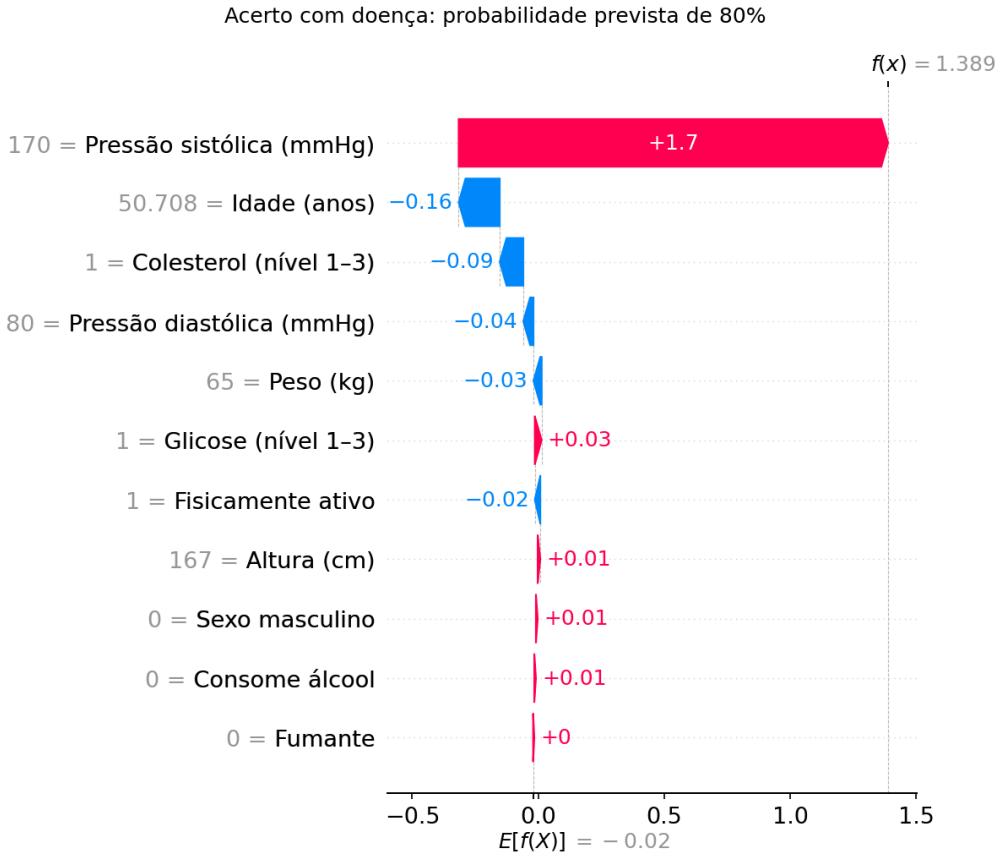


Figura 16. Cascata SHAP: paciente com doença corretamente sinalizado

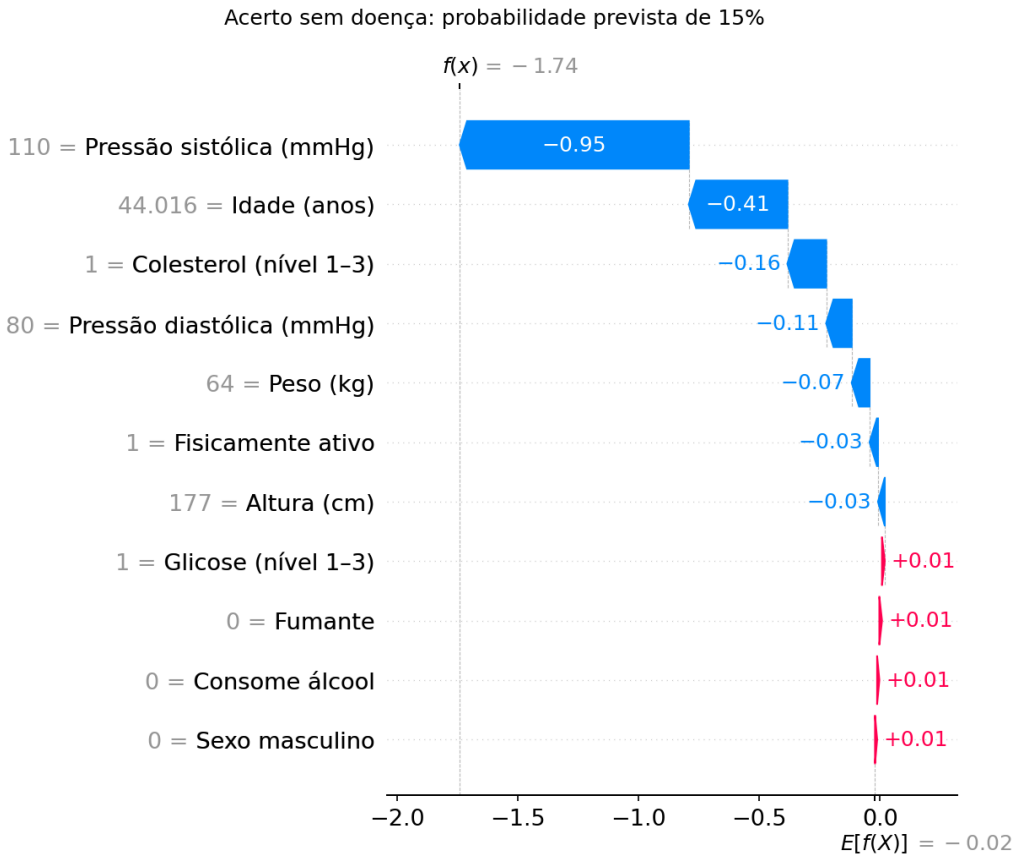


Figura 17. Cascata SHAP: paciente sem doença corretamente liberado

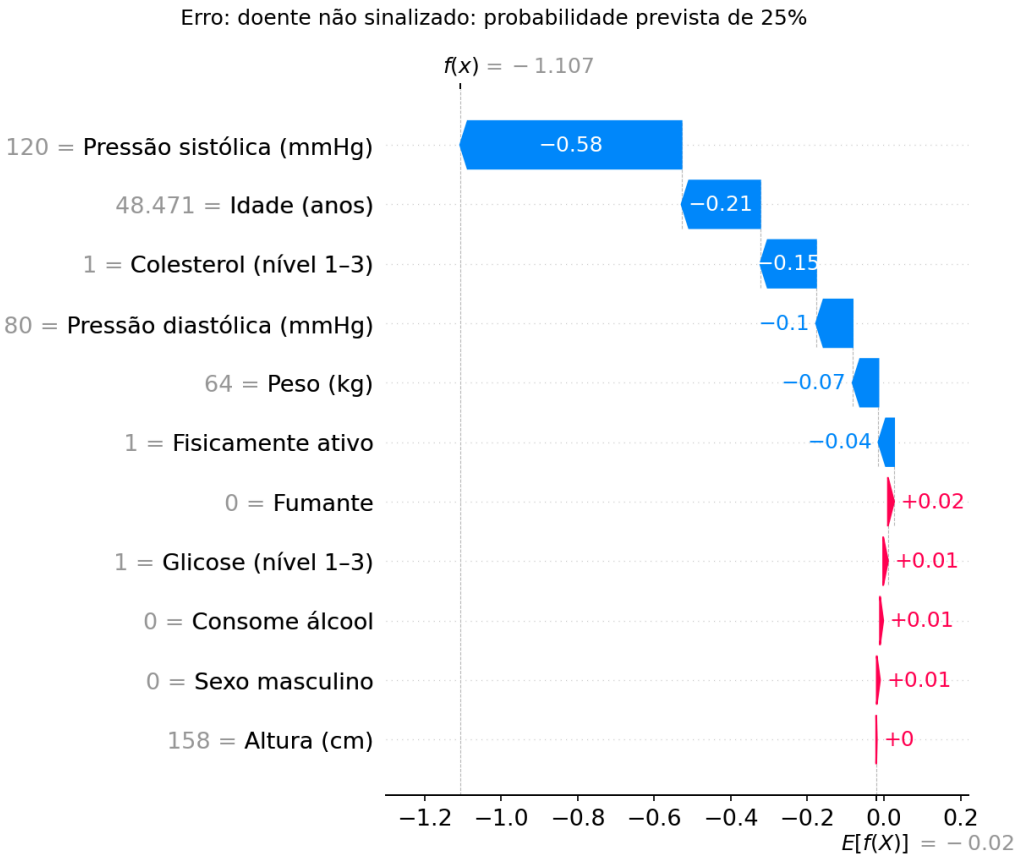


Figura 18. Cascata SHAP: paciente com doença que o modelo não sinalizou

No doente não sinalizado, a pressão (120 mmHg) parecia a de um paciente de baixo risco, e o modelo não enxerga, por exemplo, o uso de remédio para pressão.

7.3 O modelo concorda com o conhecimento clínico?

Em grande parte, sim. Pressão arterial, idade e colesterol são fatores de risco cardiovascular conhecidos e são as três primeiras variáveis do modelo, na mesma ordem em todos os métodos de permutação e no SHAP. A pressão sistólica domina, com um efeito crescente a partir do mesmo corte usado na prática clínica. O peso aparece em seguida (4ª a 5ª posição), coerente com o excesso de peso como fator de risco, e altura e sexo quase não pesam. A figura resume a posição de cada variável nos sete métodos usados na T24 (três permutações, duas importâncias nativas, o SHAP e o tamanho do efeito na Regressão Logística).

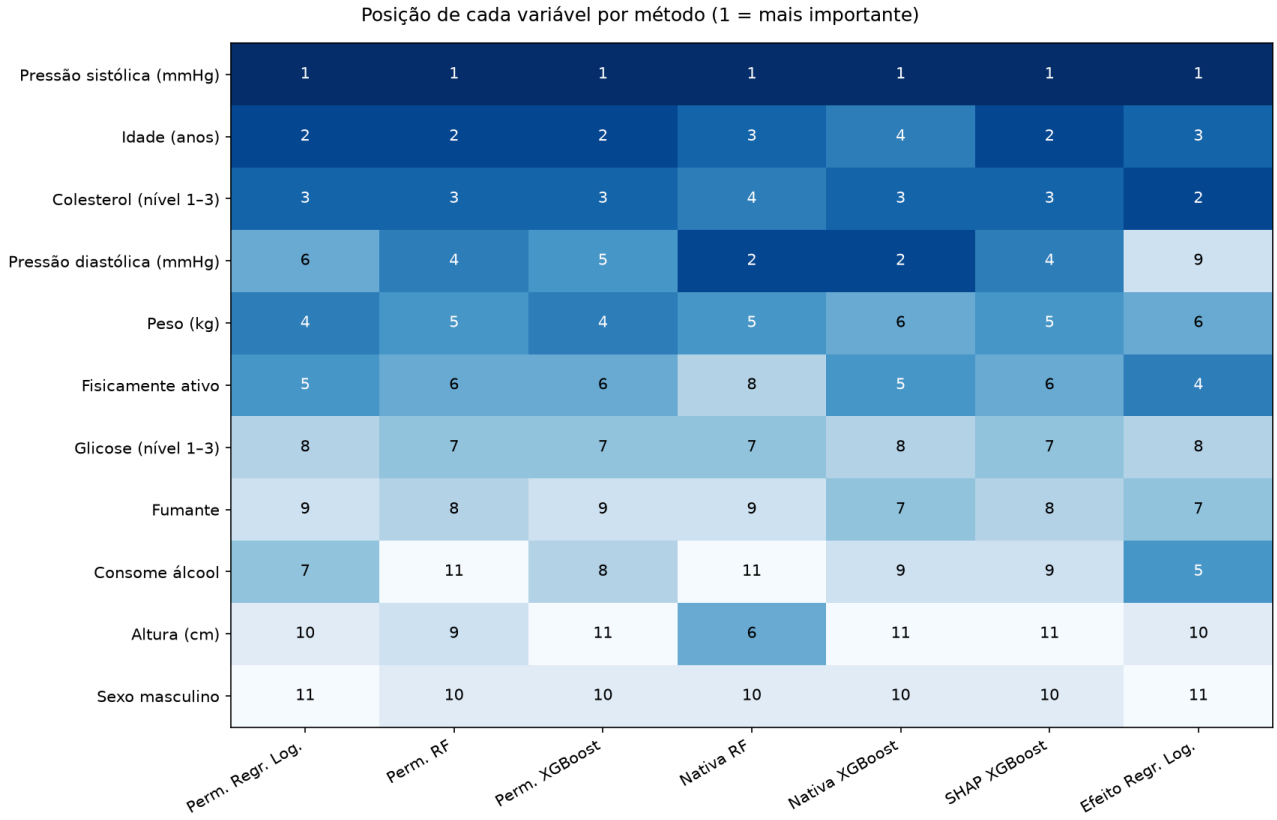


Figura 19. Posição de cada variável em cada método de importância

Dois pontos pedem cautela. A **glicose**, um fator de risco clássico, pesa pouco: ela tem só três níveis e anda junto com o colesterol, e uma explicação plausível, não testada aqui, é que parte da informação dela já entre pelo colesterol. Os **hábitos autodeclarados** também pesam pouco, e isso pode refletir a qualidade do dado (subnotificação), e não que eles não importem para o coração.

Limites. Importância mostra o que o modelo usa, não o que causa a doença, e variáveis correlacionadas dividem a importância entre si. Os números vêm de uma única divisão dos dados. O modelo é um **apoio à triagem**: o resultado não autoriza o uso isolado para diagnóstico, e a decisão final é sempre do médico.

8. Discussão crítica (uso na prática — o médico tem a palavra final)

Esta seção discute se o modelo pode ser usado na prática, onde ele falha e o que seria preciso para melhorá-lo. Os números de subgrupo vêm de `notebooks/10_analise_erros.ipynb` (T26), calculados na validação com o modelo final (XGBoost, conjunto A, limiar 0,36) treinado só com os dados de treino.

8.1 O modelo pode ser usado na prática? Como?

Sim, como apoio à triagem, nunca como diagnóstico. O uso proposto é ordenar a fila: entre os pacientes de uma consulta de rotina, indicar quais devem fazer exames cardiológicos completos primeiro. No teste, o modelo sinalizou **83 de cada 100 doentes** (recall de 83,1%), e **67 de cada 100 pacientes sinalizados** realmente tinham a doença (seção 6.4).

Na prática, isso significa:

- **"Risco alto" é um pedido de investigação, não um diagnóstico.** Um em cada três pacientes sinalizados é saudável e será liberado depois dos exames. É o custo aceito para perder menos doentes (seção 6.3).
- **"Risco baixo" não exclui a doença.** O modelo deixa passar cerca de 17% dos doentes. Um paciente com sintomas, histórico familiar ou outro motivo clínico de preocupação deve ser investigado, qualquer que seja o resultado.
- **O médico tem sempre a palavra final.** O modelo só vê 11 variáveis; o médico vê o paciente inteiro. A explicação de cada previsão (SHAP, seção 7.2) permite ao médico conferir *por que* o modelo deu aquele risco e discordar dele.

8.2 Por que o desempenho fica em torno de 73%

A acurácia fica perto de 73% (AUC de 0,79) em todos os cinco modelos, e a seção 6.5 mostra que mais dados ou modelos mais complexos não mudam isso. A explicação está nas variáveis disponíveis, e não no algoritmo:

- **Variáveis simples.** São dados de uma consulta de rotina; faltam os exames que de fato confirmam a doença.
- **Colesterol e glicose em só 3 níveis** (normal, acima, muito acima). Dois pacientes com colesterol de 250 e de 320 mg/dL podem cair no mesmo nível, e o modelo não consegue diferenciá-los.
- **Hábitos autodeclarados** (fumo, álcool, atividade física): sim/não, sem quantidade, e com sinal contrário ao esperado no fumo e no álcool (seção 3.3), o que indica subnotificação.
- **Erros de registro.** Mesmo depois da limpeza (seção 3.1), a pressão foi anotada de forma arredondada: 97% das medidas terminam em zero e 43% dos pacientes têm exatamente 120/80 ou 140/90 (seção 6.5).
- **Falta o tratamento.** Um hipertenso que toma remédio pode ter a pressão "normal" no dia da consulta. Para o modelo, ele parece saudável.

8.3 Onde o modelo erra (T26)

O desempenho não é igual para todos os pacientes. A figura mostra recall, precision e F1 por subgrupo; em vermelho, os grupos mais de 0,05 abaixo do geral.

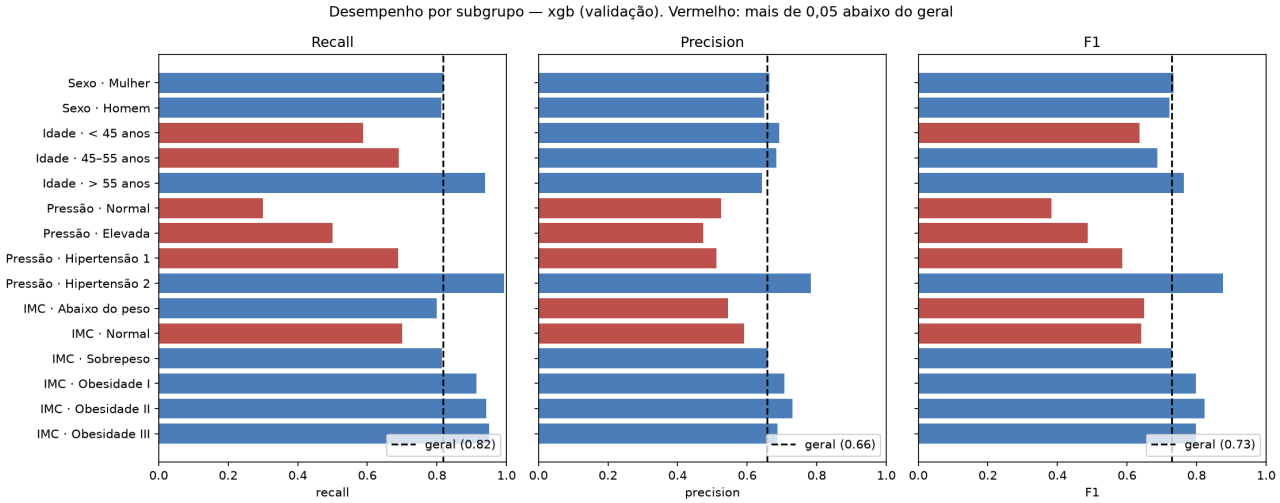


Figura 20. Desempenho do modelo final por subgrupo, na validação

Subgrupo	Pacientes	% com doença	Recall
Todos	10.277	49,5%	0,82
Mulheres / homens	6.757 / 3.520	49,3% / 49,8%	0,82 / 0,81
Idade < 45 anos	1.533	29,9%	**0,59**
Idade > 55 anos	4.640	60,1%	0,94
Pressão normal	1.487	23,9%	**0,30**
Hipertensão estágio 2	3.490	77,3%	0,99
IMC normal	3.784	39,4%	**0,70**

- **Não há diferença entre os sexos** (recall de 0,82 nas mulheres e 0,81 nos homens).
- **O modelo falha justamente em quem parece saudável.** Com pressão normal, ele encontra só **3 em cada 10 doentes**; abaixo de 45 anos, 6 em cada 10. Esses grupos têm menos doença, e os doentes deles se parecem com os saudáveis nas variáveis disponíveis.
- **Os doentes não sinalizados parecem saudáveis.** Dos 929 doentes que o modelo deixou passar na validação, 27% têm pressão normal (contra 3% dos doentes que ele encontrou) e 30% não têm nenhum fator de risco aparente (contra 11%). Na média, eles têm pressão, idade, IMC e colesterol muito próximos dos pacientes saudáveis.

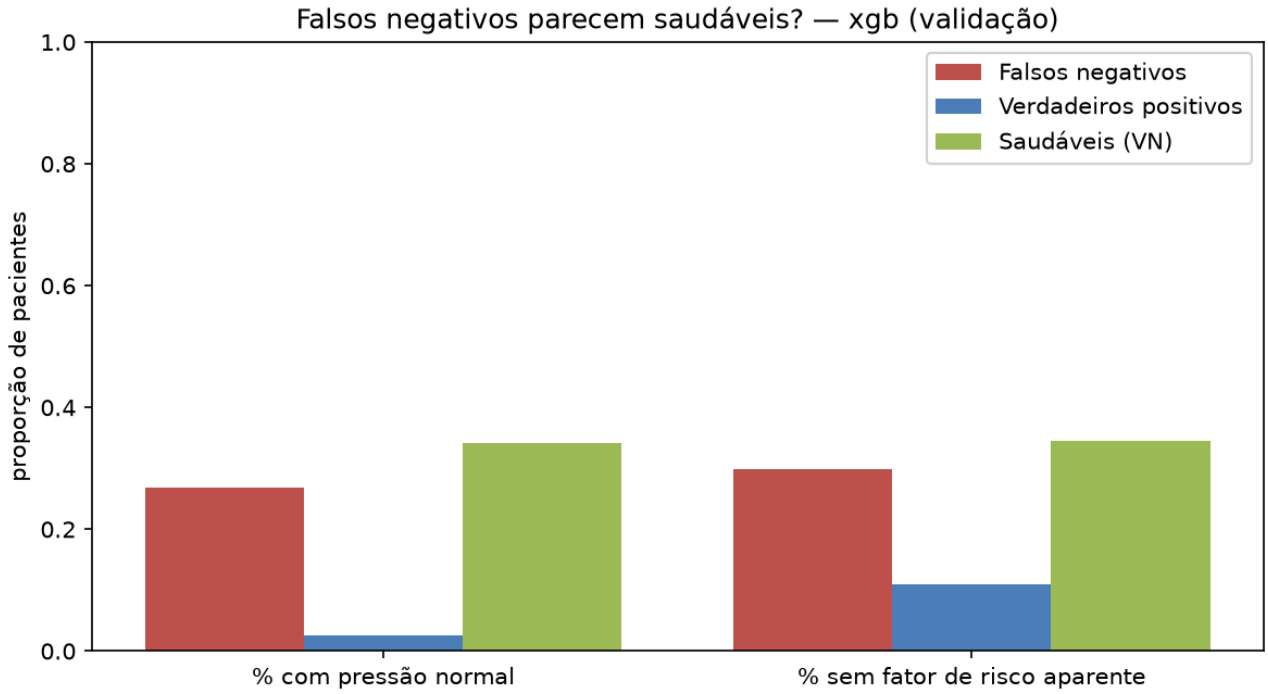


Figura 21. Falsos negativos comparados com os doentes encontrados e com os saudáveis

Consequência prática: em paciente jovem, com pressão normal ou sem fatores de risco aparentes, um resultado de risco baixo vale pouco. Nesses grupos, a avaliação clínica deve pesar mais do que o modelo.

8.4 Limitações dos dados

- **Uma única fonte, pouco documentada.** O dataset vem do Kaggle, sem informação clara sobre o país, os hospitais, o período de coleta ou como o diagnóstico foi feito. Não dá para saber a quem os resultados se aplicam.
- **Amostra que não representa a população geral:** 65% são mulheres, todos têm entre 30 e 65 anos, e metade tem a doença, uma proporção muito maior do que na população.
- **Dados transversais.** Tudo foi registrado no mesmo exame, junto com o diagnóstico. O modelo identifica **quem já tem** a doença; ele **não prevê quem vai ter** nos próximos anos. Para isso seria preciso acompanhar pacientes ao longo do tempo.
- **Uma única divisão dos dados.** Os resultados vêm de uma divisão treino/validação/teste, sem intervalos de confiança; diferenças pequenas entre modelos (menos de 0,01 de AUC) não devem ser lidas como reais.

8.5 Riscos de usar o modelo em outras populações

- **Menos doença, mais alarmes falsos.** Nos dados, metade dos pacientes tem a doença. Numa população em que só 10% têm, mantendo a mesma sensibilidade e especificidade do teste, só **19 de cada 100 pacientes sinalizados** seriam doentes (contra 67 aqui), e o risco estimado pelo modelo ficaria superestimado. O limiar e a calibração teriam de ser revistos com dados locais.
- **Idades fora da faixa.** O modelo nunca viu pacientes com menos de 30 ou mais de 65 anos; o resultado nessas idades é uma extrapolação.

- **Outros hábitos de registro.** Uma clínica que mede a pressão com mais precisão, ou que registra colesterol em mg/dL, produz dados diferentes dos usados no treino.
- **Antes de usar em qualquer serviço**, o modelo precisa ser testado nos pacientes daquele serviço e acompanhado depois da implantação, com revisão periódica dos casos não sinalizados.

8.6 Próximos passos

1. **Variáveis clínicas mais ricas:** colesterol (LDL, HDL) e glicemia em valores contínuos, uso de anti-hipertensivos e estatinas, histórico familiar, tabagismo em maços-ano e exames como o eletrocardiograma (o extra da seção 10 é um primeiro passo nessa direção).
2. **Validação externa:** testar o modelo em dados de outro hospital ou país, com a proporção real de doentes, antes de qualquer uso.
3. **Dados longitudinais:** acompanhar pacientes ao longo do tempo para prever risco futuro, como fazem os escores clínicos de risco cardiovascular.
4. **Avaliar com o médico:** medir, num estudo piloto, se a priorização reduz o tempo até o diagnóstico sem aumentar demais a fila de exames.

9. Conclusão

Com dados de uma consulta de rotina, é possível construir um apoio à triagem cardiovascular útil, mas com limites claros. Depois de limpar 1.491 registros impossíveis, os cinco algoritmos testados chegaram ao mesmo patamar de AUC na validação (0,783 a 0,792), o que indica que o limite está nas variáveis disponíveis e não no algoritmo (seção 6.5).

O modelo final, um XGBoost com as 11 variáveis originais e o limiar de decisão ajustado para 0,36, foi avaliado uma única vez no teste: AUC de 0,810 e **recall de 83,1%**, acima da meta de 80% definida para a triagem. A cada 1.000 pacientes, ele deixa de sinalizar cerca de 83 doentes e encaminha cerca de 203 pessoas saudáveis para exames de confirmação. As decisões são explicáveis: pressão sistólica, idade e colesterol respondem pela maior parte do risco estimado, em concordância com os fatores de risco conhecidos, e a pressão passa a pesar a partir de 130 mmHg (seção 7).

O uso indicado é **ordenar a fila de exames**, nunca diagnosticar. O modelo falha justamente em quem parece saudável (pacientes jovens ou com pressão normal, seção 8.3), foi treinado com uma amostra de uma única fonte e não prevê doença futura. Antes de qualquer uso real, ele precisaria de variáveis clínicas mais ricas e de validação em dados de outros serviços. A decisão final é sempre do médico.

10. Extra: diagnóstico por imagem de ECG (CNN)

Complemento opcional do desafio: classificação de **imagens de eletrocardiograma (ECG)** com redes neurais convolucionais, no pacote `src/cardio_visual/` (separado do projeto tabular, com a mesma organização). O tema é o mesmo do projeto principal (doença cardiovascular), agora a partir de outra fonte de dados: o ECG impresso de 12 derivações.

10.1 Problema e dataset

O objetivo é uma **triagem**: dado o ECG de um paciente, indicar se ele parece normal ou se há sinais de batimento anormal, de infarto em curso ou de infarto prévio, para priorizar a leitura do cardiologista. O dataset é o Cardiovascular ECG Images (Kaggle), com 4 classes: normal, batimento anormal, histórico de infarto e infarto.

A verificação do dataset (`notebooks/cnn_01_eda_imagens.ipynb` , figura `cnn_eda_duplicatas.png`) mudou o tamanho real do problema:

- O zip tem **1.376 imagens, mas só 491 diferentes**: as 448 imagens da pasta `test/` são **cópias** de imagens de `train/` , e o próprio `train/` repete imagens (cada ECG de infarto aparece até 8 vezes). Avaliar no `test/` original mediria o modelo em imagens que ele já viu.
- Imagens únicas por classe: batimento anormal 233, normal 142, histórico de infarto 86 e **infarto só 30**.
- Nenhum arquivo corrompido; todas as imagens são relatórios impressos de 2213 × 1572 px, com o mesmo layout.

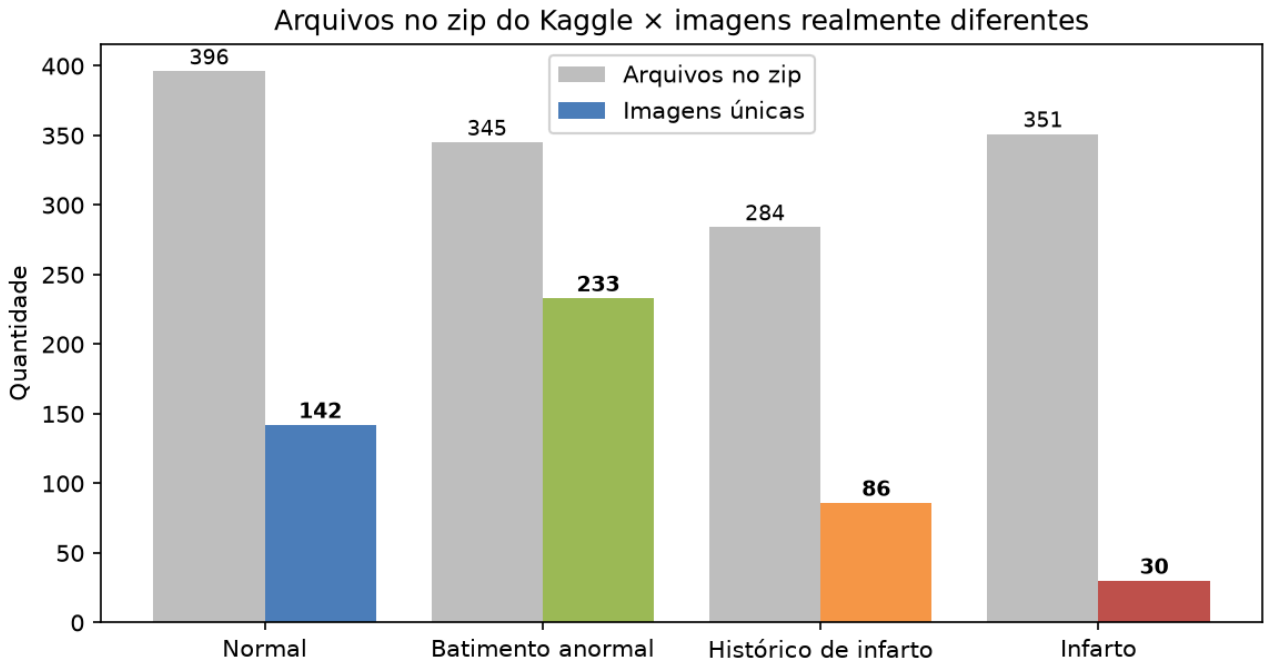


Figura 22. Arquivos no zip do Kaggle comparados com as imagens realmente diferentes, por classe

Por isso usamos **só as imagens únicas** e fizemos a nossa própria divisão. Antes dela, **1 imagem de cada classe foi sorteada e reservada para um teste cego** (`data/demo`, para o professor e a apresentação). As outras 487 foram divididas em **70/15/15, estratificado, com** `SEED = 42` (o mesmo critério do projeto tabular): 340 de treino, 73 de validação e 74 de teste, com só 4 imagens de infarto na validação e 4 no teste.

10.2 Pré-processamento

- **Recorte da grade do traçado** (`RecorteGrade`): a grade ocupa a mesma posição nas 491 folhas (pixels 68 a 2176 na horizontal e 283 a 1517 na vertical). Fora dela há só texto impresso: ID do paciente, data, hora e frequência cardíaca. Esse texto não é o ECG e poderia virar **atalho** para o modelo, então é removido antes de tudo.
- Redimensionamento para 448 × 448 px (cada derivação fica com ~110 px de largura, contra ~55 px em 224; figura `cnn_eda_resolucao.png`) e normalização do ImageNet, necessária para o transfer learning.
- **Aumento de dados só no treino**: rotação de até 2°, deslocamento de 2%, escala de ±2% e brilho/contraste. **Sem giro horizontal ou vertical**: no ECG o eixo horizontal é o tempo, e inverter a imagem cria um traçado que não existe.
- **Pesos de classe** na função de perda, para compensar o desbalanceamento.

10.3 Modelos e por quê

- **CNN simples (do zero)**: 4 blocos convolucionais e pooling global. É o baseline: mostra o que uma rede pequena aprende sem conhecimento prévio.
- **ResNet18 com transfer learning**: rede pré-treinada no ImageNet, com a última camada trocada para as 4 classes e todo o corpo ajustado (fine-tuning). Com poucas centenas de imagens, reaproveitar filtros de bordas e formas já aprendidos é a forma mais realista de chegar a um bom resultado.

Treino com Adam (taxa 0,001, lotes de 32), até 20 épocas e **parada antecipada pelo F1 macro da validação** (paciência de 5 épocas; com F1 empatado, vale a menor perda). A escolha do modelo usou **só a validação e a validação cruzada**; o teste foi usado **uma única vez**, no modelo final. Na CPU, o treino do ResNet18 leva ~6 min em 224 px e ~25 min em 448 px.

10.4 Resultados

Validação (73 imagens, `results/cnn_val_results.csv`):

Modelo	Acurácia	F1 macro (IC 95%)	Recall macro
CNN simples, 224 px	0,62	0,40 (0,33 a 0,50)	0,43
ResNet18, 224 px	0,86	0,79 (0,58 a 0,92)	0,75
ResNet18, 448 px	**0,90**	**0,85** (0,66 a 0,96)	**0,83**

Validação cruzada (5 folds sobre treino + validação, 224 px, `results/cnn_cv_results.csv`): ResNet18 com F1 macro **0,83 ± 0,05** e CNN simples com **0,60 ± 0,09**; o recall do infarto foi 0,72 ± 0,11 e 0,40 ± 0,14. O transfer learning é claramente superior. A vantagem do 448 px sobre o 224 px (0,85 contra 0,79 na validação) é do tamanho de cerca de um desvio-padrão da validação cruzada: é uma evidência fraca, e a escolha do 448 px também se apoia na EDA (mais detalhe do traçado por derivação).

Teste, modelo final ResNet18 448 px (74 imagens, avaliação única; `results/cnn_test_results.csv`, figura `cnn_cm_resnet18_448_test.png`):

Classe	Precision	Recall	F1	Imagens
Batimento anormal	0,94	0,97	0,96	35
Histórico de infarto	0,87	1,00	0,93	13
Infarto	1,00	**0,50**	0,67	4
Normal	1,00	0,95	0,98	22

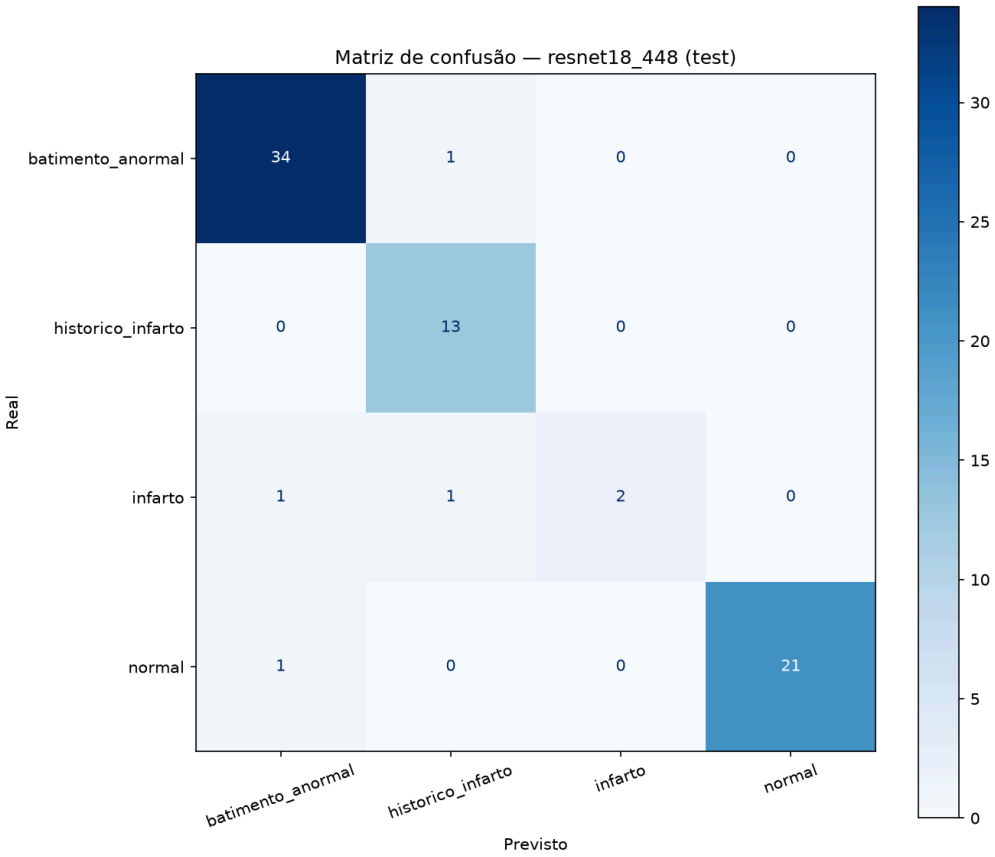


Figura 23. Matriz de confusão do modelo final de imagens (ResNet18, 448 px) no teste

Acurácia 0,95, **F1 macro 0,88 (IC 95% de 0,70 a 0,99)** e AUC média de 0,99. Na **visão de triagem** (normal × qualquer alteração), o modelo **sinalizou 100% dos ECGs alterados** com especificidade de 0,95.

Escolha da métrica. Numa triagem, o erro mais grave é o falso negativo (um ECG alterado tratado como normal). Por isso a métrica principal é o **recall por classe** (e o recall da visão binária), acompanhado de precision, F1 e AUC; a acurácia sozinha esconderia o erro nas classes pequenas. Como o teste tem poucas imagens, os resultados vêm com **intervalo de confiança** (bootstrap).

Teste cego (`notebooks/cnn_03_projeto_imagens.ipynb`): as 4 imagens reservadas foram classificadas corretamente (4 de 4); a de infarto teve a menor confiança (61%). Com 4 imagens isso é uma demonstração, não uma medida de desempenho.

10.5 Interpretação (Grad-CAM)

Para imagens, o Grad-CAM cumpre o papel da feature importance/SHAP do projeto tabular: um mapa de calor mostra as regiões que mais pesaram na decisão (`notebooks/cnn_02_interpretacao.ipynb`, figura `cnn_gradcam_val.png`).

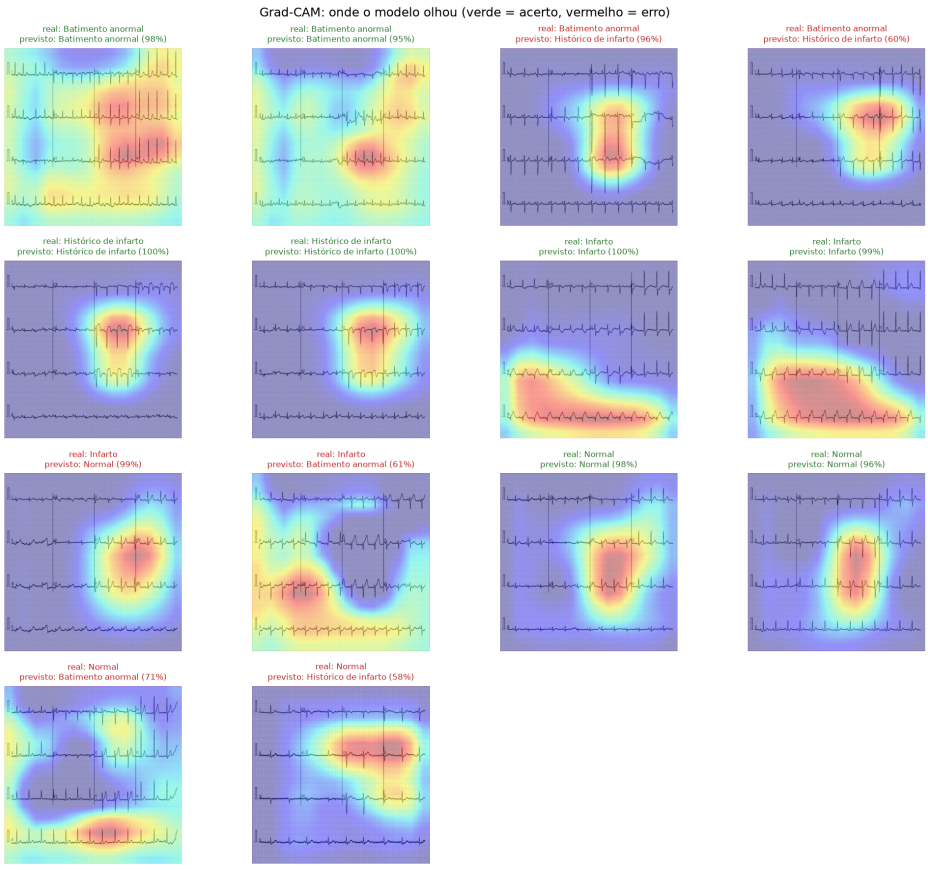


Figura 24. Grad-CAM na validação: regiões que mais pesaram em acertos (verde) e erros (vermelho)

- O calor cai sobre **derivações específicas** do traçado, e não sobre a grade em branco ou sobre texto (já removido pelo recorte). Nos acertos de histórico de infarto, ele se concentra na região das precordiais V1 a V3; nos de infarto, na tira de ritmo e nas derivações inferiores.
- A medida objetiva (quanto do calor cai sobre os pixels do traçado, comparado à área que eles ocupam) dá uma razão de 1,11. O número fica perto de 1 também porque o mapa tem só 14 × 14 células e espalha o calor pela vizinhança do traçado.
- Na validação houve 7 erros em 73 imagens, 3 deles com confiança de 80% ou mais. O pior foi um **infarto classificado como normal com 99% de confiança**.

O Grad-CAM é uma pista coerente com a leitura de um ECG (cada alteração aparece em derivações próprias), não uma prova de que o modelo reconhece a onda certa.

10.6 Discussão crítica

O modelo pode ser usado na prática? Como? Como **apoio à triagem**: ordenar a fila de ECGs para que os que parecem alterados sejam lidos primeiro. Na visão binária, ele não deixou passar nenhum ECG alterado no teste. **Não** deve ser usado para descartar infarto: a classe infarto tem só 30 imagens, o recall no teste foi de 2 em 4, e houve um infarto classificado como normal com 99% de confiança na validação. **O cardiologista tem sempre a palavra final.**

Limitações:

- **Dataset pequeno e repetitivo**: 491 ECGs diferentes, e os resultados têm intervalos de confiança largos (o F1 macro no teste pode estar entre 0,70 e 0,99).
- **Uma única fonte**: imagens do mesmo software e, provavelmente, do mesmo hospital; o desempenho em outro aparelho ou outra população não foi medido.
- **ECG impresso, não o sinal original**: a imagem perde resolução de tempo e amplitude que um cardiologista ou um modelo de sinal usariam.
- **Sem dados clínicos**: o modelo não sabe idade, sintomas ou exames anteriores, que o médico usa junto com o ECG.

Próximos passos: mais imagens de infarto, validação externa (outro hospital), modelos sobre o sinal do ECG e treino em GPU para testar resoluções maiores.

10.7 Conclusão do extra

Com transfer learning (ResNet18), o modelo chega a F1 macro de 0,88 no teste e separa ECGs normais de alterados com recall de 100% e especificidade de 95%, mas com incerteza grande e fraqueza clara na classe infarto. Ele complementa o projeto tabular como uma segunda fonte de informação para a triagem cardiovascular, sempre como apoio à decisão médica.